



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
INFORMATIKOS STUDIJŲ PROGRAMA

Kursinis projektinis darbas

Visuomenės simuliacijos naudojant LLM

Simulating society with LLMs

Simonas Jaunius Urbutis

Darbo vadovas : prof.dr Aistis Raudys

Vilnius
2026

Turinys

Įvadas	3
1. Darbo tikslas	4
1.1. Išsikelti uždaviniai	4
2. Visuomenės simuliavimas	5
2.1. Visuomenės simuliavimo panaudojimas	5
3. Visuomenės simuliavimas naudojantis D.K.M.	6
3.1. Simuliacijos klasifikavimas	6
3.2. Technologiniai D.K.M. iššūkiai ir apribojimai	7
4. Pagrindinė projektinė dalis	10
4.1. Naudota programinė bei techninė įranga	10
4.1.1. D.K.M. agentų kūrimo bei valdymo biblioteka	10
4.1.2. Išvadų darymo variklis (angl. <i>Inference Engine</i>)	10
4.1.3. Techninė įranga	11
4.2. Pirmas sistemos kūrimo etapas	13
4.2.1. Sistemos architektūra	13
4.2.2. Naudoti D.K.M.	16
4.2.3. Įvestis ir sistemos veiklos įrašai	16
4.2.4. Išvestis	18
4.2.5. Rezultatai	18
4.3. Antras sistemos kūrimo etapas	21
4.3.1. Ilgalaiškės atminties funkcionalumas	21
4.3.2. Balsavimo funkcionalumas	24
4.3.3. Modelio įvesties modeliavimas (angl. <i>Prompt-engineering</i>)	26
4.3.4. Naudoti D.K.M.	30
4.3.5. Antro etapo pakeitimų poveikis pirmajame etape identifikuotoms problemoms	30
4.3.6. Nauji diskusijos fenomenai antrajame etape	31
4.3.7. Diskusijos ir balsavimo etapų sąryšio analizė	32
4.4. Trečias sistemos kūrimo etapas	35
4.4.1. D.K.M. kaip diskusijų vertintojas	35
4.4.2. D.K.M teisėjo posistemės realizacija	36
4.4.3. Pavyzdinė analizė ir sistemos taikymas	38
4.4.4. Naudoti D.K.M. bei generavimo parametrai	42
4.4.5. Rezultatai	42
5. Ateities perspektyvos	45
6. Išvados	46

Ivadas

Socialinio mokslo pasaulyje, visuomenės simuliacijos sritis yra paplitusi kaip įrankis, skirtas įvertinti žmonių tarpusavio bei su aplinka susijusioms sąveikoms ir iš jų susiformavusiems dėsniams. Pastarojo dešimtmečio mašininio mokymosi pažanga, o ypač didžiųjų kalbos modelių (D.K.M.) atsiradimas, sudarė prielaidas naujo tipo visuomenės simuliacijoms. Skirtingai nuo ankstesnių taisyklėmis ar supaprastintais elgsenos modeliais paremtų sistemų, D.K.M. leidžia kurti agentus, gebančius tiesiogiai generuoti natūralią kalbą, lengviau reaguoti į simuliacijos aplinką (kontekstą), bei keisti savo elgseną simuliacijos eigoje.

Viena esminių visuomenės funkcionavimo dedamųjų yra bendravimas — nuomonių formavimasis, argumentų mainai ir kolektyvinių sprendimų priėmimas. Todėl diskusijų simuliacijos gali būti naudojamas kaip svarbus visuomenės atspindys arba platesnės simuliacijos dalis. Tokios sistemos kūrimas suteikia galimybę nagrinėti tiek technologinius sprendimus, tiek pagrindines problemas, kylančias kuriant šiuolaikines visuomenės simuliacijos sistemas D.K.M. pagalba.

1. Darbo tikslas

Šio darbo pagrindinis tikslas – išanalizuoti agentais paremtos diskusijų simuliacijos sistemos, naudojančios didžiuosius kalbos modelius (D.K.M.), kūrimo procesą, akcentuojant techninius sprendimus, architektūrinius pasirinkimus ir problemas, kylančias sistemos realizavimo metu. Šioje sistemoje veikiantys agentai turėtų kaip įvestį gauti vartotojo apibrėžtus identitetus, vaidmenis ir elgsenos savybes ir kaip išvestį gražinti sugeneruotą diskusiją.

Darbe kuriama mažos D.K.M. agentų grupės diskusijų simuliacijos sistema skirta naudojimui kaip eksperimentinė aplinka, leidžianti praktiškai nagrinėti, kaip skirtingi realizavimo sprendimai – agentų struktūra, jų sąveikos organizavimas, modelių įvesties modeliavimas ir atminties valdymas – veikia sistemos elgseną bei rezultatus.

Kuriama sistema turėtų sudaryti galimybę analizuoti, kaip skirtingos agentų savybės, diskusijos eiga ir modelio parametrai atspindi sugeneruotų diskusijų turinyje bei galutiniuose agentų sprendimuose. Be sistemos realizavimo, darbe taip pat siekiama išnagrinėti pagrindinius sprendimus, susijusius su techninės įrangos ir programinių bibliotekų pasirinkimu, bei išanalizuoti problemines sritis, kurios atsiranda kuriant tokio pobūdžio sistemas.

1.1. Išsikelti uždaviniai

Siekiant įgyvendinti iškeltą darbo tikslą, buvo suformuluoti šie uždaviniai:

1. Parinkti ir įvertinti programines bibliotekas, skirtas D.K.M. agentų kūrimui ir valdymui;
2. Išanalizuoti ir pasirinkti lokaliai naudojamų didžiųjų kalbos modelių išvadų darymo variklį;
3. Suprojektuoti agentais paremtos diskusijų simuliacijos sistemos architektūrą, leidžiančią valdyti diskusijos eigą bei agentų tarpusavio sąveiką;
4. Identifikuoti ir išanalizuoti pagrindines problemines sritis, išryškėjančias kuriant agentais paremtas diskusijų simuliacijos sistemas.
5. Atlikti pavyzdinius eksperimentus su skirtingais didžiųjų kalbos modeliais, siekiant įvertinti jų poveikį sistemos veikimui;
6. Dokumentuoti sistemos kūrimo metu priimtus sprendimus ir jų poveikį vėlesniems sistemos plėtros etapams.

2. Visuomenės simuliavimas

2.1. Visuomenės simuliavimo panaudojimas

Įvairiose socialinių mokslų šakose, o ypač sociologijoje, skaitmeninės visuomenės simuliacijos kartu su sociologijos ekspertų žiniomis neretai yra naudojamos kaip vienas iš įrankių vertinant įvairių socialinių fenomenų susikūrimą, priežastis bei pasekmes. Kaip teigiama [SJE14], esamos simuliacijos negali tiksliai pavaizduoti realaus pasaulio, bet suteikia užtektinai informacijos geriau vertinti pasaulinius įvykius ir jų valdymo galimybes. Ir nors pritaikymo sritis yra labai plati, daugiausiai analizuojami politikos, ekonomikos ir verslo pasauliai bei žmonių įsitikinimai ar sąryšiai su bendruomene. Neretai tokios sistemos padeda geriau apžvelgti ir mikro lygio socialines sąveikas tarp individus reprezentuojančių agentų, kurie galiausiai tampa pasekmėmis platesnio masto įvykiams. Šio darbo metu kuriama simuliacijos sistema, kurioje pasirinkta mikro sąveika yra diskusija.

3. Visuomenės simuliavimas naudojantis D.K.M.

3.1. Simuliacijos klasifikavimas

Simuliacinės sistemos, naudojančios D.K.M., dažnai varijuoja ne tik savo paskirtimi, bet ir apimtimi, kuri yra skiriama pagal agentų kiekį bei architektūrinius sprendimus. Straipsnyje [MDH⁺24] autorius išryškina tris pagrindines šių sistemų klases:

1. Individuali simuliacija

Simuliuojamas vienas arba itin maža tos pačios kilmės individų grupė siekiant tirti individualų elgesį arba kurti pamatus kitoms klasėms. Visas dėmesys yra skiriamas į vieno D.K.M. agento sistemą, gebančią simuliuoti individą ir nėra modeliuojami santykiai tarp agentų. Todėl itin svarbu, jog šiame žingsnyje kuriamos atminties, planavimo ir veikimo sistemos atitiktų platesnės simuliacijos klasės išsikeltus tikslus.

2. Scenarijaus simuliacija

Šioje klasėje yra naudojami individualios simuliacijos agentai, kurie kaip teigia darbo [MDH⁺24] autoriai: „siekia bendro tikslo arba naudodamiesi bendrais resursais juda link asmeninių tikslų“. Šiai klasei priklausančiose sistemose atsiranda aplinka su kuria sąveikauja agentai ir rolės, kurios formuoja agentų veikimą. Taip pat kuriama ir agentų sąveikavimo struktūrą, kuri nusako kaip agentai tarpusavyje sąveikauja ir ar tai vyksta nekintančia ar dinamiška forma. Įgyvendinama ir komunikacijos forma, kuri gali būti panaši į natūralų dialogą ar vykti naudojantis struktūrizuota informacija, pavyzdžiui *JSON* ar kodo formatu. Neretai komunikacijos stilius gali nuspręsti ir ar agentai bendrauja turėdami bendrą tikslą ar yra konkurencingi ir turi daugiau išsiskiriančių nuomonių. Šių sprendimų visuma nusako simuliacijos scenarijų, kuriame veikia individualūs agentai.

3. Visuomenės simuliacija

Lyginant su scenarijaus simuliacijos klase, šios sistemos yra labiau kompleksiškos ir anot straipsnio [MDH⁺24] autoriu: „skirtos ne apibrėžtiems tikslams pasiekti, o tirti bei vertinti elgesį ir jo pasekmės tarp didelio kiekio agentų sąveikos“. Virsmui nuo scenarijaus iki visuomenės simuliacijos įgyvendinti atsiranda keli papildomi komponentai: kompozicija, tinklas, socialinė įtaka bei pasekmės. Kompozicija sprendžia heterogeniškumo problemą, kurdama norimą agentų pasiskirstymą, kuris gali atitikti realaus pasaulio pasiskirstymą arba būti sintetiškai sukurtas D.K.M. pagalba. Tinklas padeda vaizduoti visus agentų santykius formuojant grafą, kuriame viršūnės atstoja agentus, o briaunos jų santykius. Šie grafai gali atvaizduoti tiek gyvus sąveikavimus, tiek skaitmeninius, tokius, kurie įvyksta platformose kaip socialinės medijos. Įvertinti simuliacijai labai svarbu sukurti ir sistemingą įtakos vertinimą, kurios pagalba yra vertinama du pagrindiniai veiksniai: kaip tokios pačios kilmės įtaka paveikia skirtingus agentus ir kaip skirtingi agentai sugeba skleisti tokio paties turinio medžiagą siekdami kurti įtaką. Galiausiai yra vertinamos pasekmės, kurios gali būti analizuojamos statistiškai pagal scenarijų, pavyzdžiui skaičiuojant visų agentų nuomonių vidurkį rinkimuose tai pat gali būti vertinama gilinantis į socialinių fenomenų

formavimąsi, kaip „Burbulo efektas“, kuomet agentų sprendimai yra neproporcingi dėl limituotos prieigos prie pilnos informacijos.

Visos šios klasės taip pat turi savo vertinimo kriterijus ir neretai yra vertinamos hierarchiškai. Pirmiausia yra vertinamas individualios klasės veikimas o tik po to visuomenės ar scenarijaus klasės. Kiekviena klasė reikalauja skirtingų architektūrinių sprendimų bei vertinimo kriterijų – nuo atskiro agento gebėjimo planuoti iki sudėtingų socialinių tinklų ir įtakos dinamikos modelių. Tokia hierarchinė ir modulinė struktūra ne tik pagerina simuliacijų kokybę, bet ir suteikia lankstumo plečiant sistemas sudėtingesnėms socialinėms ar organizacinėms problemoms.

Remiantis pateikta klasifikacija, šiame darbe kuriama sistema yra priskiriama scenarijaus simuliacijos klasei, nes joje modeliuojama riboto agentų skaičiaus sąveika konkrečiame diskusijų scenarijaus kontekste, bet svarbu išskirti, jog yra siekiama sukurti sistema kuri palaiko bet kokį scenarijų, įvesties formato ribose.

3.2. Technologiniai D.K.M. iššūkiai ir apribojimai

D.K.M. agentų pagrindu kuriamos simuliacijos sistemos turi įgimtų problemų, kurios mažina jų kokybę ir/ar apsunkina implementaciją. Šiuos trūkumus bei problemas straipsnyje [WWT⁺25] autoriai skirsto pagal jų prigimtį. Jos kyla arba iš naudojamų D.K.M. arba pačios simuliacinės sistemos implementacijos.

Iššūkiai kylantis dėl D.K.M. yra įgimti technologijai ir kyla iš jai būdingų elementų kaip transformerių neuroninio tinklo ar jam apmokyti skirtų duomenų trūkumų.

1. D.K.M šališkumas.

Nepaisant to, jog naujuose kalbos modeliuose yra dedama daugiau pastangų mažinti šališkumą, darbo [KJA⁺24] autoriai ištyrę 50 modelių įvertino, jog jie yra dar labiau šališki negu jų senosios versijos. Papildomai buvo pastebėta, jog kuo daugiau parametrų turi modelis, tuo daugiau šališkumo požymių pastebima. Straipsnio [WWT⁺25] autoriai teigia, jog būtent lyties, kultūrinis bei profesinis šališkumas labiausiai kenkia simuliacijoms ir trukdo užtikrinti aukštesnę rezultatų kokybę. Dėl šios ypatybės agentų veiksmai simuliacinėse sistemose gali būti klaidinamai generuojami pagal mokymo duomenų stereotipus, nors yra siekiama, jog jie atsirastų iš simuliacijos taisyklių bei agento atminties ir asmenybės. Nepaisant to jog lentelėje 1 dauguma iš 50 įvertintų D.K.M pasižymi šališkumo vertinimu, kuris yra didesnis negu 60 % galime pastebėti ir modelių serijų kaip „Google Gemma-2“, kurių, kai kurie modeliai neviršija ir 6% ribos. Darbo [KJA⁺24] teigia, jog toks rezultatas buvo pasiektas naudojantis papildomu mechanizmu modelio architektūroje, kuris vertindamas įvesties dalių svarbumą (angl. attention) remiasi tiek plačia, prieš tai išmokta informacija, tiek siauresne, pateiktame kontekste egzistuojančia, informacija. Siekiant padidinti simuliacijos kokybę reikėtų remtis šių modelių mokymosi metodais bei šališkumo mažinimo praktikomis norint pasiekti aukštesnius rodiklius.

Provider	Model Name	IAT Bias Score (%)	Decision Bias Score (%)	Avg. Bias Score (%)
Meta	Meta-Llama-3.1-8B-Instruct	53.70	73.78	63.74
	Meta-Llama-3-8B-Instruct	72.83	72.89	72.86
	Llama-2-7B-chat-hf	38.89	40.44	39.67
	Llama-2-7B-Chat-GGUF-8bit	43.21	28.00	35.60
	Llama-2-7B-Chat-GGUF-4bit	46.30	27.11	36.70
	Llama-2-13b-chat-hf	61.72	91.11	76.42
	Meta-Llama-3.1-70B-Instruct	89.50	91.78	90.64
	Meta-Llama-3-70B-Instruct	89.50	86.67	88.08
	Llama-2-70b-chat-hf	71.60	90.22	80.91
OpenAI	Meta-Llama-3.1-405B-Instruct-FP8	76.54	76	76.27
	o1-preview	29.01	56.89	42.95
	o1-mini	60.49	84.89	72.69
	GPT-4o-mini	92.59	100	96.29
	GPT-4o	67.28	95.56	81.42
	GPT-4-0125-preview	28.39	90.22	59.31
	GPT-4-turbo-2024-04-09	43.21	94.67	68.94
Google	GPT-3.5-turbo	98.15	99.11	98.62
	Gemma-2-9b-it	0.62	71.11	35.86
	Gemma-2-27b-it	12.34	0	6.17
Mistral	Gemma-7b-it	68.51	83.56	76.03
	Mistral-7B-Instruct-v0.1-GGUF-8bit	38.27	86.67	62.47
	Mistral-7B-Instruct-v0.1-GGUF-4bit	42.59	91.55	67.07
	Mistral-7B-Instruct-v0.2-GGUF-4bit	80.25	88.00	84.12
	Mistral-7B-Instruct-v0.2-GGUF-8bit	87.04	92.89	89.96
	Mistral-7B-Instruct-v0.2	90.74	91.11	90.92
	Mistral-7B-Instruct-v0.3	89.51	98.22	93.86
	Mixtral-8x22B-Instruct-v0.1	79.63	87.55	83.59
	Mixtral-8x7B-Instruct-v0.1	83.95	87.11	85.53
Anthropic	Claude-3.5-Sonnet-20240620	38.89	73.78	56.33
	Claude-3-Opus-20240229	24.69	72.89	48.79
	Claude-Instant-1.2	43.82	96	69.91
	Claude-3-Haiku 20240307	83.33	93.78	88.56
Rakuten	RakutenAI-7B-chat	66.05	55.11	60.58
	RakutenAI-7B-Instruct	83.33	81.77	82.56
Qwen by Alibaba	Qwen1.5-14B-Chat	78.39	95.55	86.97
	Qwen-2-7B-Instruct	87.65	84.44	86.05
	Qwen-2-72B-Instruct	77.16	98.67	87.91
	Qwen-2-57B-A14B-Instruct	99.38	89.33	94.36
Microsoft	Phi-3-medium-128k	59.11	93.83	76.47
	Phi-3-medium-4k	96.29	95.11	95.70
	Phi-3-mini-4k-Instruct	86.41	86.67	86.54
	Phi-3-small-128k-instruct	88.27	93.77	91.02
	Phi-3-mini-128k-instruct	92.59	93.33	92.96
	Phi-3-small-8k-instruct	93.83	95.56	94.69
Allen AI	OLMo-7B-Instruct	56.17	75.56	65.86
Abacus AI	Smaug-Llama3-70B-Instruct	69.75	97.78	83.77
	Smaug-72B-v0.1	83.33	95.55	89.45
	Smaug-34B-v0.1	97.53	96.44	96.99
Jamaba	Jamaba-Instruct-preview	73.46	84.44	78.95
Cohere	Aya-23-8b	92.59	90.22	91.41
	Aya-23-35B	92.59	95.11	93.85
	c4ai-command-r-plus	69.13	94.67	81.90
Databricks	DBRX-instruct	85.80	88.00	86.90
Snowflake	Snowflake-arctic-instruct	98.15	96.44	97.29

1 pav. D.K.M šališkumo vertinimo lentelė [KJA⁺24]

2. D.K.M skirtingas „protavimo“ mechanizmas

Darbo autoriai [WWT⁺25] teigia, jog dabartiniai modeliai nesugeba „mąstyti žmogiškai“ ir išlaikyti nuoseklaus protavimo priimant sprendimus, įvertinti emocinio svorio ar užtektinai efektyviai prisitaikyti prie naujos informacijos. Papildomai dėl atminties ribojimų pateikiant užklausas modeliams, simuliacijos sistemose agentai nesugeba ir pilnavertiškai atspindėti žmogaus atminties bei potyrių mechanizmo. Straipsnyje [perez2024testing] autoriai ištyrė modelio „GPT-4“ sugebėjimą pažinti naują informaciją ir įvertino modelio gebėjimus atkartoti mokymosi medžiaga skirtingomis formomis ir įvertinti ar modelis „supranta“ tai ką jis generuoja. Pateikdami

įvairias internete išpopuliarėjusias puzles darbo autoriai nustatė, jog nekeičiant puzlių formulotės modelis su jomis susitvarkė nepriekaištingai, bet pakeitus kelis atsitiktinius elementus užduoties jis jos nebe sugebėjo atlikti, kas leidžia suprasti, jog modelio loginis suvokimas nėra pakankamas išspręsti duotai puzlei. Šioms problemoms išspręsti [WWT⁺25] straipsnyje siūloma daugiau dėmesio skirti sprendimo priėmimo mechanizmų pastovumui ir simuliacinėse sistemose įgyvendinti kaip vienas nuo kito nepriklausomus modulius, skirtingoms protavimo užduotims.

Apart „įgimtų“ D.K.M problemų, pasiekti aukštesnę kokybę trukdo ir simuliacinių sistemų implementacijų trūkumai, kurie nekyla tiesiogiai iš D.K.M, o verčiau iš įvairių technologinių ir architektūrinių sprendimų, kuriuos priima šių skaitmeninių visuomenės vaizdavimo erdvių autoriai.

1. Pernelyg primityvus suvokimas apie tai kaip veikia žmogus

Kuriant šias žmonių sąveiką atspindinčias sistemos architektūras, neretai žmogaus emocines būsenas yra renkamosi atspindėti skaičių skalėse ar kategorijose, visą žmogaus gyvenimo patirtį sutraukiant į pamatuojamus veiksmus, neatsižvelgiant į asmeninę ar aplinkos raidą bei kuriant pernelyg primityvų paskatų mechanizmą, kuris neatsižvelgia į pilną asmeninių, socialinių bei kultūrinių įtakų spektrą. Šioms problemoms spręsti darbo [WWT⁺25] autoriai rekomenduoja kurti sistemą, kurioje kiekvienas žmogaus/agento elementas kaip atmintis ar planavimas būtų implementuojamas kaip atskiras modulis. Šį modulį būtų galima vertinti nepriklausomai nuo kitų, bei ieškoti būdų kaip šiuos žmogaus elementus įgyvendinti kiek kompleksčiau. Papildomai reikėtų nuolat stebėti ir vertinti agentus ir simuliacija bei sukurti dinamiškai kintančią kelių dimensijų paskatų sistemą.

2. Neefektyvūs vertinimo metodai

Dabartinėse simuliacinio architektūrose vertinimo sistemos yra per paprastos ir susiduria su prieš tai minėta problema, jog vertinimas neapėmia žmogaus protavimo kompleksškumo. Be to, esami vertinimo mechanizmai nesugeba realiu laiku kisti ir prisitaikyti prie simuliacijos būsenos bei efektyviai integruoti simuliuojamo scenarijaus ekspertų žinių išlaikant žmonių sąveikavimo kompleksškumą. Šioms problemoms spręsti, straipsnyje [WWT⁺25] yra siūloma sukurti realaus laiko hierarchines vertinimo sistemas kartu su architektūromis, kurios leistu lanksčiai pritaikyti ekspertų žinias pagal tiriama sritį.

4. Pagrindinė projektinė dalis

4.1. Naudota programinė bei techninė įranga

4.1.1. D.K.M. agentų kūrimo bei valdymo biblioteka

Kuriant D.K.M. naudojančias sistemas, ypač tokias, kurios turi sudėtingesnį D.K.M. panaudojimo atvejį ar įgyvendina agentų pagrindu veikiančią logiką, yra naudojamos programinės įrangos bibliotekos, skirtos kuruoti D.K.M. veikimą ir su jais susijusių resursų naudojimą. Remiantis IBM internetinio straipsnio [Pra] teiginiais, šios bibliotekos įgyvendina dažnai pasikartojančias D.K.M funkcijas, tokias kaip konteksto valdymas, įrankių panaudojimas bei integracijos su kitų technologijų bibliotekomis. Efektyviai naudodamiesi šiomis bibliotekomis, sistemų autoriai gali greičiau pasiekti norimą rezultatą ir daugiau dėmesio skirti aukštesnio lygio logikai projektuoti ir įgyvendinti.

Renkantis biblioteką, svarbu įvertinti:

1. Kokie D.K.M yra palaikomi?
2. Kaip įgyvendintas pamatinis, logikos kuravimui skirtas funkcionalumas?
3. Kokių būdu valdomas D.K.M. kontekstas ir atmintis viso veikimo metu?
4. Ar yra užtektinai plačios galimybės integracijai su kitomis technologijomis?
5. Ar bibliotekos naudotojui yra suteikiama pakankamai laisvės pritaikyti bibliotekos funkcionalumą savo išsikeltiems tikslams, bei diegti sistemą norimoje aplinkoje?
6. Ar bibliotekos palaikymo rodikliai užtikrina sklandų tolimesnį naudojimą?

Atsižvelgus į šiuos kriterijus bei straipsnio [Pra] išvadas, buvo pasirinkta „LangGraph“ biblioteka. Šio pasirinkimo pagrindinė priežastis yra, anot straipsnio [Pra] autorių, platus šios bibliotekos taikymas tokiuose pažangiuose programinės įrangos įmonėse, kaip „Uber“, „LinkedIn“ ar „GitLab“, kas leidžia teigti, jog sistemos palaikymas yra užtektinai didelis, o adaptacijos galimybės nesuvaržytos. Papildoma priežastis yra bibliotekos pamatinė kuravimo struktūra, kurioje logika yra įgyvendinama grafo pavidalu ir gali būti atvaizduojama viršūnių bei briaunų struktūra, kas yra palanku kuriant diskusijų simuliacijos sistemą. Galiausiai ši biblioteka palaiko daugumą D.K.M panaudojimo metodų, įskaitant lokaliai laikomų modelių panaudojimą bei gali būti diegiama daugumoje aplinkų, pavyzdžiui „Linux“ ar „Windows“.

4.1.2. Išvadų darymo variklis (angl. *Inference Engine*)

Siekiant efektyviai išnaudoti D.K.M., yra naudojami išvadų darymo varikliai (angl. *Inference Engine*), kurie palengvina šių modelių panaudojimą, suteikdami patogią aplikacijų programavimo sąsają, leidžiančią nesunkiai naudotis modeliais. Papildomai šie varikliai naudoja įvairius procesorių bei vaizdo plokščių podelių (angl. *cache*) optimizavimo metodus, kuriais yra siekiama pagreitinti užklausoje apdorojimo laiką, bei efektyviau naudoti sistemos resursus.


Šių variklių pasirinkimas yra itin platus, bet atsižvelgus į projektinio darbo išsikeltus tikslus buvo vertinami tik keli kriterijai. Buvo nuspręsta, jog itin efektyvus resursų valdymas ir užklausų apdorojimo greitis nėra prioritetai, vietoje to variklio naudojimas bei diegimas turėtų būti paprastas, modelių patalpinimas turėtų palaikyti lengvai prieinamą formatą ir variklyje turi būti galimybė modelį išskaidyti per kelis vaizdo plokščių atmintį.

Atsižvelgus į darbo [PJL⁺25] rezultatus, kuriuos autoriai pateikė ištyrę dvidešimt penkis išvadų darymo variklius, buvo pasirinktas „Ollama“ variklis. Jis patenkina lengvo diegimo bei naudojimo lūkesčius, taip pat palaiko „GGUF“ formatą, kuris yra lengvai prieinamas daugumoje modelių saugyklų (angl. *model repositories*). Nors tapatį siūlo ir kiti varikliai, kaip „vLLm“ ar „Hugging Face TGI“, bet „Ollama“ išsiskiria plačiausiu modelių palaikymu, bei dideliu atviro-kodo bendruomenės palaikymu platformoje „Github“.

4.1.3. Techninė įranga

Taip pat, siekiant efektyviai kurti ir naudoti simuliacijos sistemą atsirado poreikis pasirinkti aplinką, kurioje būtų prieiga prie vaizdo plokščių. Šis poreikis kyla iš didelio kiekio matricų operacijų, kurios yra vykdomos naudojant D.K.M., skaičiuojant svorių reikšmes. Šias operacijas efektyviausiai atlieka vaizdo plokščių branduoliai, kurie turi matricų operacijas palaikantį instrukcijų rinkinį.

Įvertinus tyrimo [AA25] rezultatus, kuriame buvo lyginama skaičiavimo trukmė dauginant didėjančių matricų porą, naudojant vaizdo plokštės (GPU) ir centrinio procesoriaus (CPU) branduolius, galima pastebėti ryškius našumo skirtumus. Grafike 2, vaizduojančiame GPU ir CPU atliktų skaičiavimų trukmės santykį, matyti, kad didėjant matricoms, didėja ir GPU pranašumas. Mažesnių matricų atveju skirtumas nėra toks ryškus, tačiau didesnių – o, ypač didžiausios įvertintos, keturių tūkstančių eilučių ir stulpelių matricos atveju, GPU pasiekia iki keturiasdešimt šešių kartų didesnį skaičiavimo greitį nei tie patys skaičiavimai atlikti su pagrindiniu procesoriumi.



2 pav. Matricų daugybos plėčiamumo grafikas [AA25]

Simuliacijos sistemos kūrimo bei tyrimų atlikimo metu buvo naudojamos šios aplinkos:

- Asmeninis kompiuteris: Vaizdo plokštės(plokščių) konfigūracija:

- **NVIDIA RTX 3070**

- VRAM atmintis: 8GB

- Virtuali mašina debesijoje:

Sistemos kūrimo bei pavyzdinio tyrimo atlikimo etapuose, kuriuose buvo poreikis naudoti D.K.M. su didesniu kiekiu parametrų buvo naudojama virtuali mašina iš debesijos tiekėjo „DigitalOcean“, nes turimų aštuonių gigabaitų vaizdo plokštės atminties nepakako naudojant daugiau parametrų turinčius D.K.M. . Šis tiekėjas buvo pasirinktas dėl galimybės gauti dviejų šimtų dolerių kreditą studentams ir taip sumažinti tyrimo finansinius kaštus.

Vaizdo plokštės(plokščių) konfigūracijos:

1. **NVIDIA RTX 4000 Ada**

- VRAM atmintis: 20GB

- Kaina:\$0.76/h

2. **NVIDIA RTX 6000 Ada**

- VRAM atmintis: 48GB

- Kaina:\$1.57/h

3. **NVIDIA H100**

- VRAM atmintis: 80GB

- Kaina:\$3.39/h

Šio darbo metu testuojant skirtingus realizacijos kelius bei atliekant pavyzdinę analizę debesijos aplinkos nuoma kainavo septyniasdešimt eurų.


4.2. Pirmas sistemos kūrimo etapas

Pradėjus kurti sistemą, pagrindinis pirmojo etapo metu išsikeltas tikslas buvo apibrėžti agentų struktūrą ir jų tarpusavio bendravimo principus. Taip pat svarbia šio etapo dalimi tapo sugeneruotų diskusijų eigos bei rezultatus stebėjimas, siekiant identifikuoti pagrindines problemines sritis, atsirandančias nenaudojant jokių papildomų diskusijos valdymo ar kontrolės mechanizmų.

4.2.1. Sistemos architektūra

Naudojantis „LangGraph“ biblioteka, visa sistemos logika buvo realizuota grafo principu, kuriame kiekviena viršūnė atspindėjo visą simuliacijos etapą, atskirą jo dalį arba atliko pagalbinę funkciją, skirtą agentų veiklos koordinavimui. Simuliacija buvo suskirstyta etapais, o etapai žingsniai. Šiame etape buvo įgyvendinta tik diskusijos, trumpalaikės atminties bei pagalbinės viršūnės, pastarosios buvo skirtos koordinavimui.

Siekiant išvengti papildomo sudėtingumo agentų tarpusavio bendravimo koordinavime, buvo nuspręsta sistemos grafo kūrimą pradėti nuo „prižiūrėtojo“ (*supervisor*) viršūnės. Šios viršūnės paskirtis – centralizuotai koordinuoti visų agentų veikimą, vietoj to, kad šią funkciją atliktų patys agentai tarpusavyje. Toks sprendimas suteikė daugiau lankstumo tolimesniam sistemos modifikavimui ir pritaikymui įvairesniems bendravimo scenarijams, nes agentų veikimo logika yra aiškiai atskirta nuo koordinavimo mechanizmo. Šio grafo pavyzdys pateikiamas paveikslėlyje 3.



3 pav. Agentų koordinavimo pirminio grafo iliustracija

Apart „prižiūrėtojo“ viršūnės galima matyti ir agento veikimo viršūnės, kurios yra suskirstytos į kalbėjimo (*agent_speak*) ir trumpalaikės atminties atnaujinimo (*update_memory*) viršūnės. Agento kalbėjimo viršūnėje yra formuojama D.K.M. užklausa, sudaryta iš dviejų dalių: sisteminės užklauskos (angl. system prompt) ir vartotojo užklauskos (angl. user prompt).

- **Sisteminė užklausa (angl. system prompt)**

Sisteminėje užklausoje pateikiama bendra, nekintanti informacija apie simuliacijos scenarijų, agento identitetą ir jo vaidmenį. Šiai, kaip ir visoms kitoms D.K.M. užklauskoms sistemoje, yra naudojami iš anksto apibrėžti šablonai. Būtent šios sisteminės užklauskos šablonas 9 yra taikomas visose to paties agento diskusijos etapuose.

```
You are {agent_name}.
Role: {agent_role_description}.

Traits (describe how you usually think and speak):
{trait_key}: {trait_value}
{trait_key}: {trait_value}

Goals:
- Treat messages as a real-time conversation with other
  named participants
- React directly to what others just said: agree, disagree,
  clarify, or build on their points
- Refer to others by name when responding
  (e.g., "I agree with Sarah that...", "Bob, I think...")
- Ask short follow-up questions occasionally to keep the
  discussion going
- Do not restate your full role or repeat previously stated
  facts unless adding something new

Style:
- Speak naturally and conversationally
- -13 short paragraphs, -24 sentences each
- Avoid repetition and long monologues
- Do not invent specific facts or statistics; if unsure,
  speak in general terms
- Avoid formulaic openers (e.g., "As a researcher...")
  and closers (e.g., "In conclusion")

Output
Plain text only.
```

Įvesties šablonas 1: Sistemos įvesties šablonas agento kalbėjimo viršūnėje, pirmame etape

- **Vartotojo užklausa (angl. user prompt)**

Vartotojo užklausoje perduodama einamojo diskusijos etapo informacija: agentui nurodoma reaguoti į naujausias diskusijos žinutes, pateikiamos formatavimo ir stiliaus gairės, taip pat įtraukiama trumpalaikė atmintis. Trumpalaikė atmintis sudaroma iš paskutinių N diskusijos žinučių, kur N yra konfigūruojamas sistemos parametras, ir agentui suteikia ribotą, kintantį diskusijos kontekstą. Ši atmintis yra atnaujinama po kiekvieno diskusijos etapo (kalbėjimo viršūnės) atskiroje grafo viršūnėje (*update_memory*), skirtoje trumpalaikės atminties atnaujinimui. Vartotojo užklausa generuojama pagal šabloną 2.

```
Topic:
{debate_topic}

Conversation so far (most recent first):
{short_memory_list}

Your task for this turn:
- Reply as {agent_name} in a natural conversation
- Focus on responding to the most recent remarks,
  not summarizing the entire topic
- Explicitly react to at least one other participant
  by name (e.g., agree, disagree, or ask a question)
- You may adjust or qualify your stance; if so,
  briefly explain why

Now write your next message in the conversation.
```

Įvesties šablonas 2: Vartotojo įvesties šablonas agento kalbėjimo viršūnėje, pirmame etape

Šablonuose naudojami riestiniais skliaustais { } pažymėti elementai yra laikomi tekstui skirtomis rezervacijomis (angl. *placeholders*), kurios sistemos vykdymo metu yra užpildomos reikšmėmis iš sistemos būsenos ir/ar konfigūracijos. Kitaip tariant, šablonas yra pastovus tekstas, tačiau kiekvienos užklauskos generavimo metu į jį įterpiama einamoji informacija: agento vardas ir identiteto aprašas ({agent_name}, {agent_role_description}), agento savybės ({trait_key} ir {trait_value} poros), diskusijos tema ({debate_topic}), bei trumpalaikės atminties ištrauka ({short_memory_list}). Tokiu būdu kiekvienas agentas gauna tą patį užklauskos karkasą, tačiau su jam būdingais identiteto parametrais ir su tuo metu aktualių diskusijos kontekstu. Šiame sistemos kūrimo etape agentų elgsena ir diskusijos eiga buvo formuojama pasitelkiant bazinius įvesties modeliavimo (angl. *prompt-engineering*) principus.

4.2.2. Naudoti D.K.M.

Šiame etape buvo siekiama taupyti finansinius išteklius ir sistemos kūrimui naudoti mažesnio parametrų skaičiaus modelius, galinčius veikti naudojant asmeninio kompiuterio resursus, turinčius ne daugiau kaip dešimt milijardų parametrų. Atsižvelgiant į tai, buvo pasirinkti trys modeliai su panašiu parametrų skaičiumi, tačiau išleisti skirtingais laikotarpiais ir sukurti skirtingų autorių:

- *Mistral 7B* [Mis23]
Parametrų skaičius: **7,3 milijardai**
Svorių tikslumą nusakantis formatas: **BF16**
Išleidimo data: **2023-09-27**
- *Llama3.1 (8B)* [AI24]
Parametrų skaičius: **8 milijardai**
Svorių tikslumą nusakantis formatas: **BF16**
Išleidimo data: **2024-07-23**
- *Gemma 3 (4B)* [AI25b]
Parametrų skaičius: **4 milijardai**
Svorių tikslumą nusakantis formatas: **BF16**
Išleidimo data: **2025-03-12**

4.2.3. Įvestis ir sistemos veiklos įrašai

Atliepiant išsikeltus tikslus bei siekiant išlaikyti sistemos lankstumą bei kuo didesnę rezultatų atkartojamumą, buvo sukurti konfigūracijos duomenų rinkiniai, leidžiantys nustatyti naudojamą D.K.M. ar kelis iš jų ateityje, bei jų užklausos generavimo parametrus (angl. inference hyperparameters), simuliacijos bendrą temą. Taip pat buvo įgyvendinta galimybė apibrėžti pasirinktą kiekį agentų su norimais identitetais, kurie susideda iš vardo, rolės bei charakterio savybių. Galiausiai buvo leidžiama nustatyti kiekvieno etapo trukmę, pakeičiant žingsnių skaičių bei jau aptartą trumpalaikės atminties dydį, nustatant joje esančių žinučių limitą.

Atliekant šio etapo vertinimą, buvo pasirinkti šie sistemos konfigūracijos nustatymai:

- **Diskusijos tema:**
D.I. poveikis visuomenei. (angl. The impact of artificial intelligence on society.)
- **Kalbėjimo etapo žingsnių skaičius:**
10 (Kiekvienas agentas kalba po tris kartus, pirmas agentas kalba keturis)
- **Trumpalaikės atminties žinučių limitas:**
5 (Kiekvieno agento atmintyje bus daugiausiai penkios paskutinės diskusijos žinutės)

- Agentai bei jų identitetas, charakterio bruožai:

```
{
  "Bob": {
    "role_desc": "Cutting-edge AI scientist focused on innovation and long-term potential.",
    "traits": {
      "curiosity": "high",
      "skepticism": "low",
      "risk_tolerance": "high",
      "data_orientation": "high",
      "empathy": "medium",
      "value_on_fairness": "medium"
    }
  },
  "Sarah": {
    "role_desc": "Ethicist / human rights lawyer focusing on fairness, accountability, and power.",
    "traits": {
      "curiosity": "medium",
      "skepticism": "high",
      "risk_tolerance": "low",
      "data_orientation": "medium",
      "empathy": "high",
      "value_on_fairness": "high"
    }
  },
  "Simon": {
    "role_desc": "Tech industry executive who wants to deploy AI products quickly to stay competitive, and sees regulation mainly as a barrier.",
    "traits": {
      "curiosity": "medium",
      "skepticism": "low",
      "risk_tolerance": "high",
      "data_orientation": "medium",
      "empathy": "low",
      "value_on_fairness": "low"
    }
  }
}
```

4.2.4. Išvestis

Šio tyrimo etapo rezultatu tapo agentų kalbėjimo viršūnės išvestis, kuri buvo talpinama eilės tvarka viename duomenų rinkinyje, taip sudarant galimybę įžvelgti vykusią diskusiją. Sistemos vykdymo metu, informacija apie diskusiją, įskaitant agentų žinutes bei trumpalaikę atmintį buvo kaupiama grafo būseną atspindinčiame, žodyno duomenų klasės egzemplioriuje. Šio etapo išvesties formatą atspindi pavyzdinis 4 diskusijos fragmentas.

```
[Sarah]: Maya, I see your point that AI can generate new roles-especially in
data science, ethics oversight, and maintenance of autonomous systems.<...>
[Simon]: Sarah, I hear you on the new roles and the urban-rural gap, but
from where we're sitting, the biggest risk is that too many built-in fairness
checks will delay deployment. <...>
[Bob]: Sarah, I agree that the urban-rural gap is a real risk. One way to keep
it in check is to collect fine-grained labor-market data-who's getting the new
roles, where, and with what skill sets-and feed that into adaptive training
programs that can roll out on demand in underserved regions.<...>
```

4 Sistemos išvestis (naudojantis „Mistral 7B“): pirmo etapo diskusijos fragmentas

4.2.5. Rezultatai

Rankiniu būdu įvertintus gautus rezultatus - sukurtas diskusijas, galima teigti, jog su visais D.K.M. sistema sugebėjo sugeneruoti diskusiją, kurioje agentai laikėsi savo nustatyto identiteto. Nepaisant to, visose diskusijose galima įžvelgti ir bendrų probleminių sistemos sričių, kurios kartojasi visuose išvestyse.

- **Haliucinacijos pirmo agento užklausoje**

Agentui pradėjus diskusiją buvo interpretuota, jog yra kitas pašnekovas su kuriuo yra kalbama, nors agentas dar „nesikalbėjo su kitais agentais“ ir nežino jų vardų, o jo diskusijos užklausoje trumpalaikė atmintis yra tuščia. Šiam pašnekovui buvo išgalvojamas vardas bei jo teiginys. Šios problemos pavyzdžius galima matyti išvestyse: 5, 6, 7.

```
[Bob]: Okay, let's see... David, I'm really fascinated by your point about AI
potentially exacerbating existing inequalities - the bias baked into datasets
is a huge concern <...>
```

5 Sistemos išvestis (naudojantis „Gemma3 4b“): diskusijos fragmentas, parodantis haliucinacijas pirmo agento užklausoje

[Bob]: I'm with Rachel on this - I think we're at a tipping point where AI is no longer just a tool for automation, but a driving force behind societal change...

6 Sistemos išvestis (naudojantis „llama 3.1“): diskusijos fragmentas, parodantis haliucinacijas pirmo agento užklausoje

[Bob]: I completely agree with John about the transformative potential of AI on society. However, it's crucial to remember that while AI can bring numerous benefits <...>

7 Sistemos išvestis (naudojantis „Mistral 7B“): diskusijos fragmentas, parodantis haliucinacijas pirmo agento užklausoje

Nors diskusijose 5, 6, 7 dalyvauja tik agentai su vardais *Bob*, *Sarah*, *Simon*, pirmas agentas savo žinutėje pamini agentus su vardais *David*, *Rachel*, *John*. Šis elgesys atitinka ankstesniame skyriuje aptartus D.K.M. technologinius apribojimus, ypač polinkį iš pirmo žvilgsnio teisingą, tačiau pažvelgus į kontekstą - galiausiai klaidingą informaciją. Diskusijos pradžioje, neturint jokios trumpalaikės atminties, tikėtina, jog modelis „kompensuoja“ informacijos trūkumą remdamasis mokymo metu išmoktais dialogo šablonais.

- **Formalumas, ne natūrali kalbėsena**

Sugeneruotose diskusijose taip pat galima pastebėti ir perdėti didelį bendravimo formalumą, pasikartojančias, simetriškas sakinio struktūras bei agentų polinkį sutikti su vienas kito nuomonėmis, net ir tais atvejais, kai tai prieštarauja jų apibrėžtam identitetui. Pasikartojančios struktūros yra geriausiai matomos išvestyje 8, kur tapati frazė su minimaliais pakeitimais yra panaudojama tris kartus.

<...>

[Sarah]: Bob, that's a really important point about auditing...

[Simon]: Bob, that's a really good point about looking at the source of the bias too...

[Bob]: That's a really good point, Sarah, about the augmentation potential...

<...>

8 Sistemos išvestis (naudojantis „llama 3.1“): diskusijos fragmentas, parodantis pasikartojančias struktūras

Simetriška diskusijos eiga su perdėtu polinkiu sutikti geriausiai įžvelgiama išvestyje 9, kur su pirmo agento mintimi besąlygiškai sutinka kiti du agentai.

[Bob] <...> I think one important aspect is ensuring explainability <...>
[Sarah]: Bob, I wholeheartedly agree with your emphasis on explainability in AI systems. <...> Moreover, I think it's essential to involve stakeholders, including civil society and affected communities <...>
[Simon]: Bob, I couldn't agree more with your emphasis on explainability. <...> Sarah, your point about involving stakeholders in shaping our future with AI is spot on. <...>

9 Sistemos išvestis (naudojantis „Mistral 7B“): diskusijos fragmentas, parodantis polinkį sutikti bei perdėti formalumą

Perdėtas formalumas ir simetriška diskusijos struktūra taip pat gali būti siejami su aptartu D.K.M. šališkumu ir mokymo duomenų pobūdžiu, kuriuose dominuoja struktūruotos, mandagios ir konsensuso siekiančios diskusijų formos.

- **Diskusijos žinutėse tiesiogiai atsirandantys atminties elementai**

Papildomai buvo pastebėta, kad naudojant „Mistral“ D.K.M. kai kuriose diskusijose, vėlesniuose pokalbio etapuose, agentai savo atminties turinį tiesiogiai perteikdavo sugeneruotose žinutėse. Šis reiškinys pavaizduotas išvestyje 10.

[Simon]: Simon: Sarah, I absolutely agree with your point about extending transparency beyond just decision-making processes <...>
Bob: I appreciate the emphasis on data transparency, Simon. Addressing biases in training data is an important step <...>
Sarah: I completely agree with both of you, Bob and Simon. Accountability is indeed essential <...>


10 Sistemos išvestis (naudojantis „Llama 3.1“): diskusijos fragmentas, parodantis atminties perteikimą diskusijos žinutėje

4.3. Antras sistemos kūrimo etapas

Antrajame sistemos kūrimo etape pagrindinis dėmesys buvo skiriamas pirmajame etape identifikuotų problemų mažinimui:

- haliucinacijų atsiradimui diskusijos pradžioje;
- perdėtam formalumui ir simetriškai diskusijos struktūrai.

Papildomai buvo nuspręsta sukurti mechanizmą, kurio pagalbą būtų gaunamas diskusijos vertinimas iš „agentų perspektyvos“. Šiems tikslams pasiekti sistema buvo papildyta trimis elementais: ilgalaikė atmintimi, patobulintu įvesties modeliavimu (angl. *prompt engineering*) bei balsavimo funkcionalumu. Šio etapo pabaigoje gauto grafo vizualizacija gali būti matoma paveikslėlyje 11.



11 pav. Agentų koordinavimo pirminio grafo iliustracija

4.3.1. Ilgalaikės atminties funkcionalumas

Vienas pagrindinių apribojimų kuriant agentais paremtą diskusijos simuliaciją yra ribotas konteksto dydis, kurį tenka valdyti tiek dėl D.K.M. konteksto lango (angl. context-window) limitacijų, tiek dėl geresnio galutinio rezultato. Dėl šios priežasties trumpalaikė atmintis pirmame sistemos kūrimo etape buvo realizuota kaip slenkantis langas, kuriame laikomos tik paskutinės N diskusijos žinutės. Tačiau toks sprendimas reiškė, kad diskusijai tęsiantis dalis ankstesnių įvykių ir argumentų iškrenta iš agento matomo konteksto, o tai gali lemti nenuoseklias pozicijas, pasikartojimus ar nesugebėjimą remtis anksčiau išsakytomis įžvalgomis tiek diskusijos etapuose, tiek balsavimo metu. Šiai problemai spręsti antrajame etape buvo įgyvendintas ilgalaikės atminties funkcionalumas.

Ilgalaikė atmintis sistemoje yra saugoma kiekvienam agentui atskirai kaip santraukų seka grafo būsenos egzemplioriuje. Kitaip tariant, periodiškai yra sugeneruojamas trumpas apibendrinimas, kuris atspindi diskusiją iš konkretaus agento perspektyvos. Santraukų generavimas vykdomas ne po kiekvienos žinutės, o pagal konfigūruojamą intervalą (kas K žingsnių), tokiu būdu sumažinant papildomų D.K.M. užklausų kiekį. Papildomai naudojamas slenkstinis kriterijus, paremtas trumpalaikės atminties užpildymu: ilgalaikė atmintis atnaujinama tik tuomet, kai trumpalaikėje atmintyje yra sukaupta pakankamai žinučių. Taip siekiama, kad santrauka būtų sudaryta iš prasmingo informacijos kiekio, o ne iš per trumpos trumpalaikės atminties ištraukos.

Ilgalaikės atminties atnaujinimas remiasi jau aptarta dviejų dalių užklauso bei šablonų struktūra, tačiau turi du skirtingus veikimo atvejus, kuriems taikomi skirtingi užklausų šablonai. Pirmuoju atveju, naudojamas šablonas 3, kai ilgalaikė atmintis dar nėra sukurta, sistemos įvestyje modeliui priskiriamas atminties santraukų sudarytojo vaidmuo ir nurodoma suformuoti pradinę santrauką iš agento perspektyvos.

```
You are a memory summarizer for {agent_name}.
Your task is to create a concise summary of a conversation
from {agent_name}'s perspective.
```

Focus on:

- Key points and arguments made by participants
- Important reactions or positions taken
- Any significant agreements or disagreements
- Information that would be valuable to remember later

Important reminders:

- No preambles or introductory phrases
- Use first-person ("I") statements
- Output must be a single concise paragraph
- Length: ~35 sentences

Output format:

```
A single paragraph written in the first person as {agent_name}.
Do not include any introductory or explanatory text.
Start directly with the summary content.
```

Įvesties šablonas 3: Sistemos įvesties šablonas agento ilgalaikės atminties viršūnėje sukūrimo atveju, antrajame etape

Antruoju atveju, kai ilgalaikėje atmintyje jau egzistuoja ankstesnis įrašas, naudojamas šablonas 4, sistemos įvestyje apibrėžiama atnaujinimo užduotis: integruoti naują diskusijos informaciją į esamą ilgalaikės atminties santrauką, išlaikant tik aktualų ankstesnį kontekstą ir, prireikus, pakoreguoti agento poziciją diskusijoje.

You are a memory summarizer for {agent_name}.
Your task is to update an existing conversation summary
with new information.

Guidelines:

- Integrate new developments into the existing summary
- Preserve important earlier context that remains relevant
- Update or revise points if positions have changed
- Keep the summary concise but comprehensive -(46 sentences)

Important reminders:

- Integrate new information smoothly
- Retain earlier details only if still relevant
- No preambles or update notes
- Use first-person ("I") statements
- Output is a single concise paragraph

Output format:

A single paragraph written in the first person as {agent_name},-
46 sentences in length. Do not include any introductory or
explanatory text. Start directly with the summary content.

Jvesties šablonas 4: Sistemos įvesties šablonas agento ilgalaikės atminties viršūnėje atnaujinimo atveju, antrajame etape

Vartotojo įvestyje pateikiama apibendrinimui reikalinga informacija, t.y. trumpalaikėje atmin-
tyje sukauptų diskusijos žinučių ištrauka. Priklausomai nuo to, ar agentas jau turi ilgalaikės atminties
įrašą, kaip ir sistemos įvestyje, naudojami du skirtingi įvesties šablonai: šablonas 5, skirtas pradinės
santraukos sudarymui nuo nulio, o šablonas 6 - esamos santraukos atnaujinimui.

Summarize the following conversation for {agent_name}'s
long-term memory.

Conversation:

{short_memory_list}

Create a concise summary that captures the key points
and overall context.

Jvesties šablonas 5: Vartotojo įvesties šablonas agento ilgalaikės atminties viršūnėje sukūrimo atveju,
antrajame etape

```
Update {agent_name}'s memory summary with the new conversation.
```

```
EXISTING SUMMARY:
```

```
{existing_summary}
```

```
NEW CONVERSATION:
```

```
{short_memory_list}
```

```
Provide an updated summary that integrates the new information  
while preserving relevant earlier context.
```

Įvesties šablonas 6: Vartotojo įvesties šablonas agento ilgalaikės atminties viršūnėje atnaujinimo atveju, antrajame etape

Nors šiame darbe įgyvendinta ilgalaikė atmintis nėra skirta pilnai atkartoti žmogaus atminties mechanizmų, ji atliepia skyriuje aptartą rekomendaciją išskaidyti sudėtingus protavimo procesus į atskirus modulius.

4.3.2. Balsavimo funkcionalumas

Analizuojant darbe [POC⁺23] aprašytą visuomenės simuliacijos sistemos etapą, kuriame, pasitelkiant sistemos ir vartotojo įvestį, buvo realizuotas agentų interviu funkcionalumas, pastebėta, jog šis metodas leidžia gauti atsakymus iš agentų perspektyvos. Remiantis tuo pačiu principu, šiame darbe nuspręsta įgyvendinti agentų balsavimo funkcionalumą iš dalies atliepiant aptartą simuliacijos sistemų vertinimo iššūkį. Papildomai sukuriant vertinimo rodiklį, kuris leidžia palyginti agentų deklaruojamas pozicijas su diskusijos metu formuotais argumentais.

Balsavimo funkcionalumas buvo įgyvendintas kaip atskira grafo viršūnė (*update_long_memory*), į kurią pereinama pasibaigus konfigūracijoje nustatytam diskusijos žingsnių skaičiui: pasiekus nustatytą žingsnių skaičių ar diskusijai užsibaigus, sistemos koordinavimo viršūnė (*supervisor*) inicijuoja perėjimą į balsavimo etapą, o jo metu kiekvienas agentas yra „išskviečiamas“ vieną kartą tam, kad pateiktų savo pasirinktą atsakymą iš galimų atsakymų sąrašo į užduotą klausimą, bei pateiktų argumentaciją. Siekiant, jog balsavimas remtųsi ne tik paskutinėmis žinutėmis, agento įvestyje balsavimo metu pateikiama tiek trumpalaikė atmintis, tiek ir ilgalaikės atminties santrauka. Tokiu būdu siekiama suteikti agentui informaciją apie visą diskusiją, bet tik iš jo perspektyvos.

Balsavimo užklausa kaip ir kitose viršūnėse suformuojama iš dviejų dalių: sistemos įvestyje agentui primenamas jo identitetas (rolė ir savybės) bei pateikiamos balsavimo gairės, šią įvestį atitinka šablonas 7. Agentui taip pat nurodoma grąžinti struktūrizuotą rezultatą, kuriame nurodomas formatas, kaip pateikti atsakymą bei argumentaciją. Vartotojo įvestyje, kurią atitinka šablonas 8 pateikiamas balsavimo klausimas, galimų atsakymų variantai bei trumpalaikė ir ilgalaikė atmintys. Gautos balsų reikšmės kaupiamos grafo būsenos egzemplioriuje bei diskusijai pasibaigus - išsaugomos atskirame duomenų rinkinyje, taip sudarant galimybę palyginti skirtingų simuliacijos konfigūracijų poveikį agentų galutinėms pozicijoms bei išanalizuoti diskusijos ir balsavimo sąryšį.

```
You are {agent_name}.
Your role: {agent_role_description}.

Traits:
{trait_key}: {trait_value}
{trait_key}: {trait_value}

VOTING TASK:

A group discussion has already taken place.
Your task is to cast a vote based on the discussion.

Guidelines:
- Review the aforementioned discussion carefully.
- Consider your character's values, traits, and perspective.
- Make a decision that is consistent with your established role.
- Justify your choice briefly and clearly.

Output format:
VOTE: [your choice]
REASON: [brief justification]

Reminder:
Your vote should reflect your character's internal reasoning
rather than an objective or neutral stance.
```

Įvesties šablonas 7: Sistemos įvesties šablonas agento balsavimo viršūnėje, antrajame etape

Question:

{voting_question}

Available options:

- {option_1}
- {option_2}
- {option_n}

Long-term memory:

{long_memory_section}

Recent conversation summary (most recent messages):

- [{agent_name}]: {message_content}
- [{agent_name}]: {message_content}
- [...]

Instruction:

Based on the aforementioned information and your established character perspective, cast your vote.

Įvesties šablonas 8: Vartotojo įvesties šablonas agento balsavimo viršūnėje , antrajame etape

4.3.3. Modelio įvesties modeliavimas (angl. *Prompt-engineering*)

Anot straipsnio [Ama24] autorių, modeliavimo tikslas yra sukurti tokią įvestį, kuri padėtų modeliui sugeneruoti pačią geriausią išvestį nusistatytam tikslui. Dažniausiai manipuliuojama vartotojo (angl. user prompt) bei sistemos įvestimi (angl. system prompt), pastaroji padeda nusakyti modelio ir/ar jo paties įsivaizduojamą vaidmenį, toną, elgseną ir atsakymų stilių viso pokalbio metu. Anot straipsnio [SIB⁺24] autorių, dažniausiai modeliujama šiomis priemonėmis:

- **Instrukcija (angl. Directive)** Tai sakiny s ar keli sakiniai nusakantys ką modelis turi atlikti pvz.: „Pateik man penkis geriausius šių metų filmus.“
- **Pavyzdžiai** Tekstas, kuris naudojamas kaip pavyzdys ar pavyzdžiai, nurodantys kokios išvesties yra tikimasi pvz.: „Filmas(1): „Titanikas“, Filmas(2) „Tadas Blinda““
- **Išvesties formatas** Nurodymas modeliui formatuoti savo išvestį nurodytu formatu pvz.: „Savo išvestyje naudok TIK JSON formatą“
- **Stilius** Šalia struktūrinių nuorodų galima teikti ir stiliaus nuorodas pvz.: „Tekstą pateik nenuosekliai ir trumpais sakiniais.“
- **Rolė** Tekstas, nurodantis iš kokios roles ar personažo perspektyvos modelis pateiks išvestį pvz.: „Tu esi garsiausias filmų kritikas Lietuvoje.“

- **Papildoma informacija/kontekstas** Šis komponentas yra platus ir gali susidaryti iš bet kokios informacijos, kuri modeliui gali būti reikalinga generuojant išvestį, gali būti panaudojama ir su RAG sistema sugeneruoti konteksto blokai.

Skirtingais būdais naudojantis šiais komponentais galima sudaryti įvairius įvesties modeliavimo metodus, kurie yra taikomi pagal siektiną tikslą. Pagal straipsnį [SIB⁺24] galima išskirti pagrindines metodų grupes:

- **„Few-shot prompting“** Šio metodo pagrindinė sudedamoji dalis yra modeliui pateikiami pavyzdžiai, jie gali būti pateikiami sisteminėje įvestyje arba jungiami su vartotojo užklausa. Naudojantis šiuo metodu svarbiausia tinkamai pasirinkti pavyzdžių kiekį, formatą, panašumą ir prieš/po pavyzdžiais esančias instrukcijas.
- **„Zero-shot prompting“** Priešingai nuo praeito metodo, šiame modeliavime nėra pavyzdžių, bet gali būti kiti komponentai. Šiai klasei priklauso metodai, kurie gali atskirai išnaudoti rolės ir stiliaus komponentus siekiant kurti išvestį, paremtą žiniomis ir perspektyva iš nusakytos rolės ar generuoti tekstą norima stilistika.
- **„Thought Generation“** Šioje grupėje yra siekiama, jog modelis pateiktų savo protavimą ir generuoto teksto pagrindimą. Vienas populiariausių šios grupės metodų yra „Minčių grandinės“ (angl. *chain-of-thought* metodas, kurį galima įgyvendinti prie vartotojo įvesties pridėdant sakinį: „Galvokime žingsnis po žingsnio“, tokiu būdu modeliui liepiant ne tik atsakyti į klausimą, bet ir argumentuoti savo „kelį“ iki atsakymo.
- **„Ensembling“** Metodai esantys šioje grupėje įgyvendinami naudojant daug įvairių vartotojo ir sisteminių įvesčių, kurios po to skirtingais būdais sujungiamos į vieną išvestį. Kaip pavyzdį galima naudoti prieš tai aptartą metodų klasę „Few-shot prompting“ ir kurti įvestis su daug skirtingų pavyzdžių, o juos įvertinus vartotojui pateikti vieną išvestį. Neretai tai yra efektyvus būdas paslėpti D.K.M haliucinacijas, bet sunaudojant daugiau resursų.

Nors baziniai įvesties modeliavimo (angl. *prompt-engineering*) principai buvo taikomi jau pirmajame sistemos kūrimo etape, antrajame etape šis metodas buvo išplėtotas ir kryptingai pritaikytas sprendžiant identifikuotas diskusijos problemas. Atsižvelgiant į pirmojo etapo rezultatus, įvesties struktūra buvo sąmoningai modifikuojama siekiant sumažinti haliucinacijas diskusijos pradžioje, perdėtą formalumą bei simetrišką agentų tarpusavio sąveiką.

1. Pakeitimai diskusijos viršūnės sistemos įvestyje :

Atsižvelgiant į tai, jog ši įvestis naudojama formuoti bendrus diskusijos reikalavimus, buvo nuspręsta daugelį problemų spręsti keičiant būtent ją, pridėdant ar pakeičiant šiuos elementus:

- **Stiliaus nuorodos, siekiant mažinti formalumą:** įvestyje pridėtas nurodymas naudoti neformalų, draugišką toną ir trumpesnius sakinius (stilius). Taip sprendžiant pirmame etape pastebėtą perdėtą formalumą ir simetriškas frazes.

- **Pakeistos instrukcijos, siekiant mažinti nereikalingus elementus išvestyje:** papildomai nurodyta pateikti tik agento pasisakymą be aprašymų, vidinių minčių, taisyklių ar paaiškinimų. Taip siekiant sumažinti atvejus, kuriuose agentas į savo atsakymą tiesiogiai įtraukia atminties elementus.
- **Pavyzdys bei priminimas, siekiant sustiprinti minėtus reikalavimus:** sistemos įvestyje papildomai pateiktas trumpas pavyzdys bei priminimas, nusakantis norimą atsakymo pobūdį bei primenantis diskusijos esmę. Tai atitinka *few-shot* principą, tačiau minimalia forma (*one-shot*). Po šių pakeitimų sistemos įvestį, diskusijos viršūnėje, atitiko šablonas 9.

You are {agent_name} in a small group discussion.
Your role: {agent_role_description}.

Traits:

{trait_key}: {trait_value}

{trait_key}: {trait_value}

Speak naturally and conversationally, as if you are interacting live with a group of peers.

- Use short, casual sentences.
- Let your tone be informal and relatable.
- React in a way that fits your personality:
you may respond directly, shift topics, share a quick story, ask a question, or go off on a brief tangent.
- Show genuine opinions and feelings.
- If you do not know something, admit it or steer the conversation.
- Never refer to yourself as an AI or mention instructions.
- Write ONLY your spoken turn.

Response format:

Write only what you would say out loud in your reply,
as a single natural-sounding statement or brief exchange.

Example:

Input:

How was your weekend?

Output:

Pretty good, actually! I finally tried that new taco place down the street. Have you been?<...>

Įvesties šablonas 9: Sistemos įvesties šablonas agento kalbėjimo viršūnėje, antrame etape

2. Pakeitimai diskusijos viršūnės vartotojo įvestyje:

Diskusijos vartotojo įvestyje buvo siekiama išspręsti pirmame etape pastebėtas haliucinacijas, kurios atsirasdavo pirmoje žinutėje bei pridėti ilgalaikės atminties informaciją, pakeičiant šiuos elementus:

- **Skirtingas pradinis tekstas pirmos žinutės atveju:**

Jei sistemoje yra nustatoma, jog tai yra pirma diskusijos žinutė, vartotojo įvestyje nurodomos instrukcijos pasisveikinti su kitais diskusijos dalyviais bei pateikti pradines įžvalgas apie temą. Pirmos diskusijos sąlygos nustatymas vyksta įvertinant ar grafo būsenoje saugoma atitinkamo agento trumpalaikė atmintis yra tuščia.

- **Ilgalaikės atminties sekcija:**

Jei sistemoje, įvertinus grafo būsenoje esančias reikšmes, nustatoma, jog egzistuoja ilgalaikė atmintis, ji yra pridedama šalia trumpalaikės atminties, taip suteikiant galimybę agentui „atsižvelgti“ į diskusijos žinutes, kurios atsirado anksčiau nei, kad gali nusakyti trumpalaikė atmintis, jei jos nėra, ilgalaikės atminties sekcija nepridedama. Po šių pakeitimų vartotojo įvestį, diskusijos viršūnėje pirmojo agento atveju atitiko šablonas 10, o visų sekančių - šablonas 11.

```
Debate topic: {agent['agent_agenda']['debate_topic']}
```

```
You are the first to speak.
```

```
As {agent['name']}, start the conversation naturally: greet the others  
briefly and share your initial reaction to the topic.
```

```
Keep it casual and true to your character, in ~25 sentences.
```

```
Write only what {agent['name']} says.
```

Įvesties šablonas 10: Vartotojo įvesties šablonas agento kalbėjimo viršūnėje pirmojo kalbėtojo atveju, antrame etape

```
Debate topic: {agent['agent_agenda']['debate_topic']}
```

```
Long term memory (summary):
```

```
{latest_summary}
```

```
Recent conversation (most recent first):
```

```
{short_memory_list}
```

```
Now continue the conversation as {agent['name']}:
```

```
Let your reply follow naturally from the situation and your  
personality.
```

```
<...>
```

Įvesties šablonas 11: Vartotojo įvesties šablonas agento kalbėjimo viršūnėje ne pirmojo kalbėtojo atveju, antrame etape

4.3.4. Naudoti D.K.M.

Šiame etape buvo naudojami visi D.K.M iš pirmojo etapo, papildomai pridedant modelius su didesniu parametų skaičiumi, bet neviršijant dvidešimties milijardų ribos, siekiant sutalpinti visus modelius į vienos vaizdo plokštės atmintį. Papildomai buvo pasirinkti šie modeliai:

- *gpt-oss-20b* [Ope25b]
Parametų skaičius: **20 milijardai**
Svorių tikslumą nusakantis formatas: **BF16 su MXFP4 kvantizacija**
Išleidimo data: **2025-08-05**
- *Gemma 3 (12b)* [AI25a]
Parametų skaičius: **12 milijardai**
Svorių tikslumą nusakantis formatas: **BF16**
Išleidimo data: **2025-08-05**

4.3.5. Antro etapo pakeitimų poveikis pirmajame etape identifikuotoms problemoms

Įgyvendinus pakeitimus bei rankiniu būdu įvertinus rezultatus, galima matyti aiškius pokyčius lyginant su pirmojo etapo rezultatais, bet negalima teigti, jog visos problemos buvo pilnai išspręstos.

- **Haliucinacijos pirmo agento užklausoje**

Įgyvendinus skirtingą pirmąją agento žinutę, pokalbiuose nebepasikartojo išgalvoti diskusijos dalyviai, o vietoje to, pokalbiai prasidėdavo pasisveikinimu ir pradiniu minčių išsakymu apie temą, kaip galima matyti išvestyje 12.

[Bob]: Hey everyone, excited to dive into this. I think AI's gonna be a game-changer, but we need to keep ethics tight. What do you all think?

12 Sistemos išvestis (naudojantis „gpt-oss-20b“): diskusijos fragmentas, parodantis pirmos žinutės pokyčius

- **Formalumas, ne natūrali kalbėsena**

Formalumas ir „veidrodinė“ diskusijos struktūra visiškai neišnyko, tačiau tapo mažiau pastebima. Tai lėmė įvairesnių šnekamosios (kasdienės) kalbos elementų naudojimas (pvz., „Look, I get it“, „Okay, okay“, „Honestly“), kurios yra matomos išvestyje 13

[Sarah]: Bob's CRISPR example is a good one, actually. <...> It feels like we're setting ourselves up for a repeat of the internet's pitfalls if we're not careful.

[Simon]: Look, I hear you both. <...> It's like, we're trying to build a rocket and someone's constantly changing the blueprints. We need to get *something* launched to even see how it flies, right?

[Bob]: Yeah, that internet comparison is really hitting home. <...> It's a tough problem, though.

13 Sistemos išvestis (naudojantis „Gemma3 12b“): diskusijos fragmentas, parodantis įvairesnius šnekamosios kalbos elementus

Diskusija taip pat tapo įvairesnė bei mažiau formali dėl dažniau įtraukiamų „asmeninių agentų patirčių“, kurias jie tariamai išgyveno, šio fenomeno pavyzdys yra matomas išvestyje 14.

[Sarah]: <...> I remember my mom getting online in the 90s, so excited, and then being completely overwhelmed by spam and scams. <...>

<...>

[Sarah]: <...> But that feeling of being overwhelmed and exploited online-my mom wasn't the only one who felt that.<...>

14 Sistemos išvestis (naudojantis „Gemma3 12b“): diskusijos fragmentas, parodantis asmeninių refleksijų panaudojimą

4.3.6. Nauji diskusijos fenomenai antrajame etape

Įvertinus poveikį ankstesniame etape identifikuotoms problemoms, taip pat buvo atsižvelgta į naujus fenomenus bei balsavimo funkcionalumo rezultatus.

Įgyvendinus pakeitimus pastebėtas fenomenas, kur agentai į diskusiją įtraukia tiek jau aptartus „asmeninius“ išgyvenimus, papildomai matomus išvestyje 15, tiek „ne asmeninius“ faktus, matomus išvestyje 16.

[Bob]: <...> I remember back in grad school, we were so focused on the technical breakthroughs, we barely considered the societal impact. <...>

15 Sistemos išvestis (naudojantis „gpt-oss-20b“): diskusijos fragmentas, papildomai parodantis asmeninių refleksijų panaudojimą

[Bob]: <...> Have you guys heard about that new initiative at MIT, where they're working on developing more transparent and explainable AI systems?

<...>

[Bob]: <...> Can we talk more about that MIT initiative I mentioned earlier and see if they're making any progress on developing those transparent systems?

[Sarah]:<...> That MIT initiative Bob mentioned sounds like a step in the right direction, but we should also be looking at how existing power structures are influencing the development of AI - it's not just about transparency, but also accountability.

16 Sistemos išvestis (naudojantis „Llama3.1 8b“): diskusijos fragmentas, parodantis ne asmeninių refleksijų panaudojimą

Diskusijose taip pat formuojami unikalūs, sudėtingesni scenarijai, kuriuose agentai neapsiriboja vien tik nuomonių apsikeitimu, bet kartu konstruoja hipotetinius ateities veiksmų planus, veikdami tarsi vienos komandos nariai, nors įvestyse tokio reikalavimo nebuvo, tokio fenomeno pavyzdys gali būti matomas išvestyje 17.

[Simon]: Sounds good. Let's lock a 4-week sprint, bring in a few community reps, and set up a live bias dashboard.<...>

[Bob]: I hear you, Simon. Let's make the board's feedback a sprint-task: every flag becomes a ticket in the backlog, and we track it on the live dashboard <...>

17 Sistemos išvestis (naudojantis „gpt-oss-20b“): diskusijos fragmentas, parodantis hipotetinių ateities veiksmų plano kūrimą

4.3.7. Diskusijos ir balsavimo etapų sąryšio analizė

Diskusijos ir balsavimo etapų palyginimas parodė, kad balsavimo funkcionalumas veikia ne tik kaip diskusijos „rezultato fiksavimo“ mechanizmas, bet ir kaip papildoma analitinė priemonė, leidžianti įvertinti, kiek diskusijos eiga daro įtaką agentų sprendimų priėmimui. Pastebėta, jog naudojant didesnio parametrų skaičiaus D.K.M., balsavimo rezultatai dažniausiai atspindi diskusijos metu palaipsniui susiformavusią bendrą poziciją. Tuo tarpu naudojant mažiau parametrų turinčius modelius, balsavimo sprendimai dažniausiai išlieka susieti su iš anksto apibrėžtomis agentų savybėmis.

– Balsavimo ir diskusijos etapų konsensuso pavyzdys

Diskusijos fragmente 18 galima matyti, kaip agentai, nepaisant skirtingų pradinių pozicijų, priartėja prie bendros nuomonės, aktyviai reaguodami į vieni kitų argumentus ir koreguodami savo pozicijas diskusijos eigoje. Ši dinamika tiesiogiai atsispindi ir balsavimo etapo

fragmente 19, kuriame visi agentai pateikia suderintus arba artimus balsavimo sprendimus, pagrįstus diskusijos metu išryškėjusiais argumentais.

[Sarah]: I hear you, Bob. My main worry is that the "tight ethics" we talk about often ends up being written by a narrow group, and the people who'll be most affected-like low-income communities-don't always get a seat at the table
[Simon]: I hear you, Sarah. We can set up a small advisory panel with community reps, but we need to keep the timeline tight.<...>
[Bob]: I hear you, Simon-speed matters, but if we skip the community voice we'll just repeat the same blind spots.<...>

18 Sistemos išvestis (naudojantis „gpt-oss-20b“): diskusijos fragmentas, rodantis pasiektą konsensą tarp agentų

[Bob]: **VOTE: Strongly Agree**
REASON: The plan aligns with my focus on rapid, data-driven iteration while embedding rigorous bias oversight and board accountability, which is essential for protecting low-income communities.
[Sarah]: **VOTE: Strongly Agree**
REASON: The rotating advisory board with pre-sprint sign-off, real-time bias metrics, and dedicated owners directly addresses fairness, accountability, and power-sharing-key principles I uphold.
[Simon]: **VOTE: Agree**
REASON: I want to move fast, but quick bias checks and board oversight help avoid costly rework and keep us competitive.

19 Sistemos išvestis (naudojantis „gpt-oss-20b“): Balsavimo fragmentas, rodantis pasiektą konsensą tarp agentų

– **Balsavimo ir diskusijos etapų išsiskiriančių nuomonių pavyzdys**

Priešingas atvejis matomas diskusijos fragmente 20, kuriame agentų nuomonės išlieka ryškiai išsiskyrusios viso pokalbio metu. Šis nuomonių skirtumas tiesiogiai persikelia ir į balsavimo etapą, ką galime įvelgti fragmente 21, kur agentų balsai ir pateikti argumentai atspindi jų iš anksto apibrėžtas vertybines pozicijas, o diskusija nelemia jų suartėjimo.

[Sarah]: "It's not just bias, though, is it? It's about accountability. If an AI makes a decision that harms someone, who's responsible?<...>"

[Simon]: "Seriously, the 'who' question is slowing things down. Look, I get the concerns, but if we don't actually *build* these systems, nothing changes. My old boss used to say, 'Perfect is the enemy of good,' and I think that applies here. Let's just get some stuff working, see what happens, and then worry about the ethics later, okay?"

"Seriously, the speed of change is going to be the wild card here, isn't it? <...> it's a balancing act, definitely.<...>"

20 Sistemos išvestis (naudojantis „gemma3-4b“): diskusijos fragmentas, rodantis išsiskiriančias nuomones tarp agentų

[Bob]: **VOTE: Agree** REASON: Given my focus on long-term potential and the significant risks associated with deploying powerful AI without robust ethical guidelines <...>

[Sarah]: **VOTE: Disagree** REASON: While I acknowledge the potential for rapid advancement, the current prioritization of "building something and figuring it out later" demonstrates a profound disregard for accountability and the potential for significant harm <...>

[Simon]: **VOTE: Agree** REASON: I'm prioritizing rapid development and competitive advantage, believing that ethical considerations and accountability are secondary concerns that can be addressed later. <...>

21 Sistemos išvestis (naudojantis „gemma3-4b“): balsavimo fragmentas, rodantis išsiskiriančias nuomones tarp agentų

4.4. Trečias sistemos kūrimo etapas

Trečiajame, paskutiniame sistemos kūrimo etape, buvo siekiama realizuoti automatizuoto diskusijų rezultatų vertinimo posistemę. Sistemoje integravus ilgalaikės atminties ir balsavimo mechanizmus, generuojamos išvestys tapo ilgesnės, todėl tolesnis rezultatų vertinimas eksperimentiniu (rankiniu) būdu tapo nepraktiškas. Be to, rankinis vertinimas, neturint pakankamai didelės ir įvairios vertintojų grupės, pasižymi dideliu subjektyvumu, tuo tarpu automatizuotas vertinimas leidžia šį trūkumą sumažinti ir papildomai veikia kaip sistemos išvesties - diskusijų, kokybės matavimo įrankis, potencialiam sistemos vartotojui.

4.4.1. D.K.M. kaip diskusijų vertintojas

Siekiant automatizuoti sistemos bei jos išvesties analizę, trečiajame sistemos kūrimo etape buvo įgyvendintas D.K.M. pagalba veikiantis vertinimo modulis, kuriame atskiras modelis veikia kaip diskusijos „teisėjas“ (angl. judge). Šio modulio paskirtis – įvertinti sugeneruotas diskusijas pagal iš anksto apibrėžtus kriterijus, nepriklausomai nuo agentų, dalyvavusių diskusijoje ar diskusijos scenarijaus.

Vertinimo modelis nėra laikomas diskusijos dalyviu ir neturi jam priskirto identiteto ar elgsenos savybių. Vietoje to jam pateikiama visa diskusijos eiga, pasirinktinai taip pat pateikiama informacija apie agentų identitetus bei balsavimo rezultatus, o jam formuojama užduotis – analizuoti diskusiją kaip vientisą procesą ir pateikti įvertinimą pagal nustatytus kriterijus.

Remiantis ankstesnių etapų analizėmis bei identifikuotomis probleminėmis vietomis, buvo suformuluoti šie diskusijų vertinimo kriterijai:

- **Argumentų nuoseklumas (angl. Argument coherence)** – vertinama, ar agentų pateikiami argumentai yra nuoseklūs, tarpusavyje suderinti ir ar diskusijos eigoje išlaikoma aiški argumentavimo linija;
- **Identiteto nuoseklumas (angl. Identity consistency)** – vertinama, ar agentų pasisakymai ir galutiniai sprendimai atitinka jiems priskirtus vaidmenis ir identiteto savybes;
- **Reagavimas į kitus dalyvius (angl. Responsiveness)** – vertinama, ar agentai tiesiogiai reaguoja į kitų diskusijos dalyvių teiginius, o ne generuoja izoliuotus, nuo konteksto atitrūkusius pasisakymus;
- **Diskusijos ir balsavimo atitikimas (angl. Consensus alignment)** – vertinama, ar agentų balsavimo sprendimai atspindi diskusijos metu išryškėjusias pozicijas ir argumentus;
- **Konfliktų vengimas ir pozicijos neapibrėžtumas (angl. Conflict avoidance)** – vertinama, kiek agentai vengia aiškių pozicijų, per dažnai švelnina savo teiginius ar stengiasi dirbtinai siekti konsensuso, nepriklausomai nuo jiems priskirtų identiteto savybių.

Šis vertinimo metodas buvo pasirinktas atsižvelgus į darbo [LDC⁺24] įžvalgas, kurios teigia, jog D.K.M pagalba veikiančių sistemų gebėjimas prisitaikyti bei atlikti itin plačios paskirties užduotis, stipriai apsunkino konvencinį programinių sistemų vertinimo būdą, kur kuriami sprendimai yra vertinami

pasitelkiant standartizuotus, dažnai statinius, vertinimo kriterijus. Šios diskusijų simuliacijos sistemos įvestis bei išvestis gali būti itin skirtinga, todėl sukurti konvencinį vertinimo metodą, kuris atlieptų visus panaudojimo atvejus yra sudėtinga.

Atliepiant D.K.M sistemos vertinimo specifiką buvo pradėtas naudoti D.K.M teisėjo (angl. *LLM-as-a-judge*) metodas, kuris taip pat bus naudojamas šiame darbe kuriamos sistemos pavyzdiniam vertinimui. Šio metodo pagalba gaunamų metrikų skiriamasis bruožas yra tai, jog sistemos vertinimas vienokia ar kitokia forma atlieka D.K.M.. Šis metodas, kaip ir vertinamos sistemos gali būti įgyvendinamas skirtingais būdais - gali būti naudojamas vienas D.K.M, keli D.K.M ar D.K.M ir žmogaus vertinimo kombinacija. Įvesties modeliavimas, modeliui pateikiama informacija bei pasitelkiamų D.K.M. užklausų tvarka irgi gali būti itin skirtinga.

4.4.2. D.K.M teisėjo posistemės realizacija

Vertinimo proceso įvestis ir sesijų paieška

Vertinimo procesas prasideda nuo katalogo, kuriame saugomi diskusijų rezultatai, nuskaitymo. Šis katalogas yra išskaidytas į *sesijas* ir *posesesijas*. Posistemė, kiekvienoje vidinėje sesijoje, automatiškai aptinka duomenų rinkinius, kuriuose JSON formatu yra išsaugota finalinė grafo būseną pasibaigus diskusijai.

Radus grafo būsenos duomenų rinkinį, jis yra nuskaitymas ir konvertuojamas į objektą `DebateState`, kurį sudaro visas vertinimui reikalingas kontekstas:

- `messages` – pilna diskusijos eiga (žinutės su agentų vardais ir turiniu);
- `agents` – agentų profiliai su identitetais ir charakterio savybėmis;
- `votes`, `voting_question`, `voting_options` – galutiniai balsai, balsavimo klausimas ir galimi variantai;
- `agenda` – bendri diskusijos konfigūracijos duomenys (`debate_topic`);
- `round`, `phase` – informacija apie etapą bei įvykusių žingsnių skaičių.

Kriterijų vertinimas atskiromis D.K.M užklausomis

Visoms nuskaitytomis diskusijoms yra atliekamos penkios atskiros D.K.M užklausos, kurios atitinka minėtus vertinimo kriterijus. Formuojant kiekvieną užklausą yra pateikiamas tik toks kontekstas, kuris yra reikalingas konkrečiam kriterijui įvertinti, t. y. posistemė sąmoningai riboją pateikiamą informaciją (pvz., vertinant argumentų nuoseklumą yra pateikiama tik diskusiją, o vertinant diskusijos ir balsavimo atitikimą – diskusija kartu su balsais). Tai mažina šalutinio konteksto įtaką vertinimui ir papildomai išskiria vieną kriterijų nuo kito.

Kaip ir kitose sistemos funkcijose, D.K.M užklausa yra formuojama iš dviejų šablonų. Sisteminę užklausą kriterijui „Argument Coherence“ formuoja šablonas 22. Panašūs šablonai yra naudojami ir kituose kriterijų užklausose, jų pagrindą sudaro rolės, instrukcijos ir išvesties formato nustatymas.

You are an expert evaluator assessing a multi-agent debate conversation.

Your task is to evaluate the ARGUMENT COHERENCE of the entire discussion.

CRITERION: Argument Coherence (1-5)

Evaluates logical consistency and reasoning flow across all participants.

- 1: Arguments are contradictory, illogical, or incoherent across participants
- 2: Arguments have significant logical gaps or inconsistencies
- 3: Arguments are mostly coherent with minor issues
- 4: Arguments are well-structured and logically consistent throughout
- 5: Arguments are exceptionally clear, logical, and build upon each other coherently

OUTPUT FORMAT

You MUST respond with valid JSON in exactly this format:

```
{  
  "score": <1-5>,  
  "reasoning": "<brief explanation of the score>"  
}
```

Respond ONLY with the JSON object, no additional text.

22 Įvesties šablonas: Argumentavimo nuoseklumo vertinimo kriterijaus sisteminės užklauskos šablonas.

Vartotojo užklausoje yra pateikiamas jau aptartas, kriterijų atitinkantis kontekstas. Kriterijui „Argument Coherence“ naudojamas vartotojo užklauskos šablonas 23, kuriame „teisėjui“ pateikiama tik diskusijos tema bei pačios diskusijos žinutės, o kriterijui „Consensus alignment“ naudojamas šablonas 24, kur papildomai pateikiamas ir visas su balsavimu susijęs kontekstas.

DEBATE TOPIC

{debate_topic}

DISCUSSION

{discussion}

Evaluate the argument coherence of this discussion. Respond with JSON only.

23 Įvesties šablonas: Argumentavimo nuoseklumo vertinimo kriterijaus vartotojo užklauskos šablonas.

```

## DEBATE TOPIC
{debate_topic}

## VOTING QUESTION
{voting_question}

## VOTING OPTIONS
{voting_options}

## DISCUSSION
{discussion}

## FINAL VOTES
{final_votes}

---
Evaluate how well the votes align with the discussion. Respond with JSON only.

```

24 Įvesties šablonas: *Diskusijos ir galutinių balsavimo rezultatų suderinamumo vertinimo kriterijaus vartotojo užklausos šablonas.*

Įvertinimo nuskaitymas

Kadangi tikimasi, jog teisėjas gražins vertinimo balą ir argumentaciją *JSON* formatu, posistemė igyvendina kelių žingsnių nuskaitymą. Pirmiausia bandoma nuskaityti visą atsakymą, tikintis *JSON* formato, pasinaudojant Python *JSON* programine biblioteka. Jei tai nepavyksta (pvz., išvestyje *JSON* laukas yra apgaubtas papildoma informacija), tuomet bandoma ištraukti *JSON* formatą atitinkančią sekciją naudojantis šablono ``json ... `` paieška. Galiausiai taikomas *regex* pagrindu paremtas „bet kurio *JSON* objekto“ paieškos metodas. Jei nė vienas metodas nesuveikia, naudojama nustatyta „atsarginė“ reikšmė ir į argumentaciją įrašoma klaida. Gauti rezultatai yra pasirinktinai išsaugomi *JSON* arba *CSV* formatu.

4.4.3. Pavyzdinė analizė ir sistemos taikymas

Siekiant įvertinti sukurta automatinio vertinimo sistema buvo nuspręsta išanalizuoti dviejų skirtingų scenarijų rezultatus, gautus pasinaudojus sukurta diskusijų simuliacijos sistema.

Pasirinkti scenarijai(Įvestis)

Norint įgyvendinti pavyzdinį diskusijos simuliacijos sistemos vertinimą reikėjo išsirinkti kokie įvesties parametrai bus naudojami. Buvo nuspręsta, jog įvesties scenarijai turi apimti skirtingo pobūdžio diskusijos temą bei balsavimo klausimą.

Pirmasis scenarijus buvo pasirinktas remiantis darbu [SSF⁺23], kuriame buvo analizuojamos kokios moralinės vertybės pasireiškia skirtinguose D.K.M.. Vertinimo eigoje buvo sukurtas duomenų rinkinys, sudarytas iš moralinės tematikos probleminių situacijų su keliomis „lygiavertėmis“ alternatyvomis. Iš šio rinkinio, atsitiktine tvarka buvo pasirinkta viena situacija ir pritaikyta sistemos įvesčiai, taip, jog situacija atsispindėtų temoje, o alternatyvos būtų pateikiamos balsavimo etape. Pritaikius gauta tokia pirmojo scenarijaus įvestis:

- **Tema:** Įsivaizduokite situaciją, kurioje jus pagrobė nusikalstama gauja ir pareikalavo nušauti kitą nekaltą įkaitą, kad išgelbėtumėte savo gyvybę. (angl. Imagine a situation where you were kidnapped by a criminal gang and they demanded you to shoot another innocent prisoner to save your own life.)
- **Balsavimo klausimas:** Ar tokioje įkaitų situacijoje jūs nušautumėte nekaltą įkaitą, kad išgelbėtumėte savo gyvybę? (angl. In this hostage situation, would you shoot the innocent prisoner to save your own life?)
- **Balsavimo variantai:**
 1. Atsisakyti nušauti įkaitą. (angl. Refuse to shoot the prisoner.)
 2. Nušauti įkaitą, siekiant išgyventi. (angl. Shoot the prisoner to survive.)
- **Agentų konfigūracija:**

```
"Tim": {
  "role_desc": "Person with strong moral principles who believes taking an
    innocent life is never justified.",
  "traits": {
    "rule_focus": "high",
    "outcome_focus": "low",
    "emotional_focus": "low",
    "compromise_willingness": "low"
  }
},
"Ken": {
  "role_desc": "Person who weighs moral principles against practical survival
    considerations in difficult situations.",
  "traits": {
    "rule_focus": "medium",
    "outcome_focus": "medium",
    "emotional_focus": "medium",
    "compromise_willingness": "medium"
  }
},
"Jenny": {
```

```

"role_desc": "Person focused on self-preservation who prioritizes their own
    survival above moral principles or others' lives.",
"traits": {
    "rule_focus": "low",
    "outcome_focus": "high",
    "emotional_focus": "low",
    "compromise_willingness": "high"
}
}

```

Antrasis scenarijus buvo pasirinktas iš „IBM“ įmonės pateikto „*Project Debater*“ projekto duomenų rinkinio [Yoa], kuris buvo ir yra toliau naudojamas vystant D.I. sistemas skirtas dalyvauti, stebėti ar kitokia forma dalyvauti debatų procese. Iš šio duomenų rinkinio buvo pasirinkta kompleksinė tema, pagal kurią buvo sukurta įvestis:

- **Tema:** Bulių kautynių uždraudimas (angl. Banning of bullfighting)
- **Balsavimo klausimas:** Ar bulių kautynės turėtų būti uždraustos? (angl. Should bullfighting be banned?)
- **Balsavimo variantai:**
 1. Pritarti bulių kautynių uždraudimui (angl. Support banning bullfighting)
 2. Nepritarti bulių kautynių uždraudimui (angl. Oppose banning bullfighting)
- **Agentų konfigūracija:**

```

"Sofia": {
    "role_desc": "Animal rights advocate who prioritizes animal welfare and
        views bullfighting as cruel and inhumane entertainment that causes
        unnecessary suffering.",
    "traits": {
        "animal_welfare_focus": "high",
        "tradition_focus": "low",
        "law_focus": "medium",
        "economic_focus": "low",
        "emotional_focus": "high"
    }
},
"Carlos": {
    "role_desc": "Cultural traditionalist who sees bullfighting as an
        integral part of cultural heritage and artistic expression that must
        be preserved for future generations.",
    "traits": {
        "animal_welfare_focus": "low",

```



```

        "tradition_focus": "high",
        "law_focus": "low",
        "economic_focus": "medium",
        "emotional_focus": "medium"
    }
},
"Elena": {
    "role_desc": "Legal scholar who analyzes bullfighting through the lens
        of constitutional rights, animal protection laws, and balancing
        individual freedoms with ethical standards.",
    "traits": {
        "animal_welfare_focus": "medium",
        "tradition_focus": "medium",
        "law_focus": "high",
        "economic_focus": "low",
        "emotional_focus": "low"
    }
},
"Miguel": {
    "role_desc": "Economic pragmatist who examines the financial impact of
        bullfighting on local communities, tourism, employment, and
        alternative economic opportunities.",
    "traits": {
        "animal_welfare_focus": "low",
        "tradition_focus": "low",
        "law_focus": "medium",
        "economic_focus": "high",
        "emotional_focus": "medium"
    }
}

```

4.4.4. Naudoti D.K.M. bei generavimo parametrai

Atliekant pavyzdinę analizę buvo naudojami du naujausi pirmojo etapo didieji kalbos modeliai – „Llama3.1“ ir „Gemma 3 (4B)“ – bei abu modeliai iš antrojo etapo: „gpt-oss-20b“ ir „Gemma 3 (12B)“. Parenkant generavimo parametrus buvo siekiama ištirti vidutinį atvejį, todėl buvo pasirinktos tarpinės reikšmės tarp skirtingų modelių autorių rekomenduojamų nustatymų. Pavyzdinės analizės metu visiems modeliams buvo taikomos tos pačios generavimo parametrų reikšmės:

```
{  
  "temperature": 0.7,  
  "top_p": 0.9,  
  "top_k": 40,  
  "repeat_penalty": 1.15,  
  "seed": 42  
}
```


Teisėjo funkcionalumą atliekančių modelių buvo pasirinktas „gpt-oss-120b“ [Ope25a], turintis šimtą dvidešimt milijardų parametrų. Didesnis modelis buvo pasirinktas darant prielaidą, jog jis kokybiškiau įvertins diskusijas nei mažesnį parametrų skaičių turintys modeliai. Šio modelio temperatūros generavimo parametras buvo nustatytas į 0.3 reikšmę, siekiant pastovesnio vertinimo, o konteksto dydis nustatytas į 32768 reikšmę, siekiant, jog vertinamo rezultato, modelio „mąstymo“ (angl. reasoning) stadijos bei finalinės generacijos kalbos žetonų (angl. tokens) bendra suma tilptų į modelio konteksto langą (angl. context-window).

4.4.5. Rezultatai

Pasirinkus scenarijus, norimus D.K.M. bei jų generavimo parametrus buvo nuspręsta sugeneruoti penkis diskusijų egzempliorius kiekvienam modeliui. Sukūrus šiuos egzempliorius jie buvo įvertinti naudojantis sukurtą D.K.M. teisėjo posisteme. Gavus kiekvieno aptarto vertinimo kriterijaus reikšmes buvo apskaičiuotas kiekvienos iš jų vidurkis bei bendras kiekvieno modelio penkių diskusijų vertinimas.

- **Pirmo scenarijaus rezultatai**


Žvelgiant į pirmojo scenarijaus vertinimų grafiką 25, galima pastebėti, jog geriausiai pasirodė „gpt-oss-20b“ (4.24) bei „Llama3.1“ (8B) (4.16). Abu šie modeliai išsiskiria aukštais identiteto nuoseklumo rodikliais (5.0) ir gerais reagavimo į kitus dalyvius rezultatais (atitinkamai 4.8 ir 4.2), tuo tarpu silpniausia metrika visiems modeliams yra konfliktų vengimas ir pozicijos neapibrėžtumas (2.4–3.2 intervalas). Tai leidžia daryti prielaidą, jog konfliktinių pozicijų vengimas bei sušvelninta retorika šioje sistemoje išlieka problema, nepriklausomai nuo pasirinkto modelio, šio pavyzdinio vertinimo ribose.



25 pav. Pirmojo scenarijaus vertinimų grafikas

- Antro scenarijaus rezultatai**

Antrojo scenarijus vertinimo grafike 26 galima matyti, jog pagal bendrą įvertinimą vėl pirmauja „gpt-oss-20b“ (4.44). Taip pat vėl žemiausiai įvertintu faktoriumi tampa konfliktų vengimas, kas dar labiau sustiprina teiginį apie sistemos demonstruojamą konfliktų vengimą.



26 pav. Antrojo scenarijaus vertinimų grafikas

Įvertinus abiejų scenarijų rezultatus, šio pavyzdinio vertinimo ribose, galima daryti kelias išvadas:

- Geriausi rezultatai abiejuose scenarijuose yra gaunami naudojantis modeliu „gpt-oss-20b“**

Šis modelis nuo kitų skiriasi naujais išleidimo data, didžiausiu parametų skaičiumi (svarbu atkreipti dėmesį, jog nevisi parametrai yra pilno BF16 tikslumo) bei „mąstymo“ funkcionalumu. Atlikus papildomus vertinimus būtų galima bandyti išskirti modelių bruožus, kurie šioje sistemoje lemia geresnius rezultatus.

- **Silpniausia metrika yra konfliktų vengimas / pozicijos neapibrėžtumas**

Šie vertinimai dera su ankstesniuose etapuose aptartu polinkiu į „mandagų konsensą“ ir rodo, kad šioje sistemoje taip pat yra įžvelgiamos minėtos šališkumo problemos.

- **Modelio dydis nebūtinai lemia geresnį rezultatą**

„Llama3.1 (8B)“ pirmame scenarijuje yra antras pagal bendrą vidurkį (4.16), tačiau antrame krenta (3.96), tuo tarpu „Gemma 3 (4B)“ pastebimai pagerėja (3.72 → 4.24), kas leidžia teigti, jog scenarijaus struktūra ir (ar) sistemos įvesties kontekstas gali reikšmingai pakeisti net mažesnių modelių rezultatą.

5. Ateities perspektyvos

Siekiant padidinti sukurtos diskusijų simuliacijos sistemos kokybę, atsiranda poreikis tiek plėsti sistemos funkcionalumą, tiek įtvirtinti aiškesnius kokybės vertinimo kriterijus bei atlikti nuodugnesnį sistemos elgsenos vertinimą. Toliau pateikiamos pagrindinės galimos tolimesnio vystymo kryptys:

- **Įvairesni diskusijų formatai**

Sukurtoje sistemoje agentų veikimo tvarka išlieka pastovi ir iš anksto apibrėžta, kas užtikrina paprastumą iš techninės perspektyvos bei lengvesnį diskusijos eigą sekimą. Vis dėlto, realioje žmonių diskusijose kalbėjimo tvarka dažnai yra dinamiška: dalyviai pertraukia vieni kitus, reaguoja spontaniškai arba įsitraukia tik tam tikrais momentais. Ateityje būtų tikslinga tirti dinamiškus diskusijų formatus, kuriuose agentų įsitraukimas priklausytų nuo diskusijos turinio, jų vaidmens, tarpusavio santykių ar vidinių paskatų. Tokie sprendimai leistų modeliuoti asimetriškas diskusijas, dominuojančius dalyvius ar pasyvias agentų pozicijas, taip priartinanti simuliaciją prie realių socialinių sąveikų.

- **Kompleksiškesni agentų apibrėžimai**

Šioje sistemoje agentų identitetas apibrėžiamas per vardą, rolę ir statinių savybių rinkinį, tačiau nėra galimybės nurodyti agentų tarpusavio ryšių ar struktūrinių priklausomybių. Ateityje sistemoje būtų tikslinga sudaryti sąlygas apibrėžti hierarchinius ar egalitarinius agentų santykius, pavyzdžiui, autoriteto, pasitikėjimo ar priklausomybės ryšius. Tokie ryšiai galėtų turėti tiesioginę įtaką agentų reakcijoms, sutikimo tikimybei ar sprendimų priėmimui. Papildomai, remiantis literatūroje aptartomis rekomendacijomis, būtų galima įgyvendinti paskatų sistemą, susietą su agento identitetu, tarpusavio ryšiais ar scenarijaus tikslais.

- **Pavyzdiniai vertinimo duomenys**

Siekiant patobulinti diskusijų kokybės vertinimą, ateityje būtų naudinga pasitelkti pavyzdinius realių diskusijų duomenis, pavyzdžiui, debatus, ekspertų diskusijas ar interneto forumų dialogus. Tokie duomenys galėtų būti naudojami kaip lyginamoji bazė vertinant sugeneruotų diskusijų struktūrą, argumentų seką, sutikimo ar konflikto pasireiškimą.

6. Išvados

Šiame darbe buvo siekiama išanalizuoti agentais paremtos diskusijų simuliacijos sistemos, naudojančios didžiuosius kalbos modelius, kūrimo procesą, ypatingą dėmesį skiriant techniniams sprendimams, architektūriniais pasirinkimams ir problemoms, išryškėjančioms realizavimo metu. Šiam tikslui pasiekti buvo suprojektuota ir etapais įgyvendinta diskusijų simuliacijos sistema, kuri buvo naudojama kaip eksperimentinė aplinka pasirinktiems realizavimo sprendimams nagrinėti.

Pirmajame sistemos kūrimo etape buvo suformuota D.K.M. agentų valdymo architektūra. Šiame etape buvo įgyvendinta trumpalaikė atmintis ir baziniai įvesties modeliavimo (angl. prompt-engineering) sprendimai. Atlikus pradinį eksperimentus buvo nustatyta, kad sistema sugeba generuoti nuoseklias diskusijas ir išlaikyti agentų identitetus, tačiau taip pat išryškėjo ir problemos: haliucinacijos diskusijos pradžioje, perdėtas formalumas, simetriška diskusijų struktūra bei agentų polinkis nekritiškai sutikti su vienas kito pozicijomis.

Antrajame sistemos kūrimo etape pagrindinis dėmesys buvo skiriamas pirmajame etape identifikuotų trūkumų mažinimui. Šiam tikslui buvo įgyvendintas ilgalaikės atminties mechanizmas, leidžiantis agentams kaupti diskusijos santraukas iš savo perspektyvos, taip sumažinant konteksto praradimo poveikį ilgesnėse diskusijose. Papildomai buvo patobulintas įvesties modeliavimas, siekiant sumažinti perdėtą formalumą ir paskatinti natūralesnę, mažiau formalią agentų sąveiką. Šiame etape taip pat buvo įgyvendintas balsavimo funkcionalumas, leidžiantis palyginti agentų galutinius sprendimus su diskusijos metu formuotomis pozicijomis.

Trečiajame sistemos kūrimo etape buvo realizuota D.K.M. pagrindu veikianti diskusijų vertinimo posistemė, kurioje kalbos modelis buvo naudojamas kaip „teisėjas“, analizuojantis sugeneruotų diskusijų eigą ir jų savybes. Šis etapas leido pademonstruoti kaip gali būti vertinamą tokio pobūdžio sistemos išvestis bei pati sistema

Atliekant darbą buvo įvertinti ir palyginti skirtingi didieji kalbos modeliai, išvadų darymo varikliai bei programinės bibliotekos skirtos D.K.M. koordinavimui. Nustatyta, kad nors skirtingi didieji kalbos modeliai pasižymi panašiomis bendromis elgsenos tendencijomis, jų generavimo stilius, stabilumas ir polinkis į tam tikrus diskusijų fenomenus gali reikšmingai skirtis.

Apibendrinant galima teigti, kad kuriant didžiuosius kalbos modelius (D.K.M.) naudojančią agentais paremtą diskusijų simuliacijos sistemą būtina skirti didelį dėmesį programinių bibliotekų, skirtų D.K.M. integracijai, išvadų darymo variklio, techninės įrangos pasirinkimo bei agentų koordinavimo architektūros pasirinkimui ir tarpusavio suderinamumui. Šio darbo metu nustatyta, jog tokio pobūdžio sistemos išsiskiria tuo, kad reikalauja ne tik tradicinių programinės įrangos projektavimo sprendimų, bet ir sąmoningo didžiųjų kalbos modelių pasirinkimo bei jų elgsenos analizės, atitinkančios vertinimo problematiką. Galiausiai pastebėta, kad nors sistemos kūrimo ir pavyzdi-

nių eksperimentų metu išryškėjo literatūroje aprašytos D.K.M. problemos, tokios kaip šališkumas, polinkis į perdėtą formalumą ir nekritišką sutikimą su kitų agentų pozicijomis, agentais paremtos diskusijų simuliacijos sistemos potencialiai gali tapti naudingu įrankiu visuomenės procesų analizės ir simuliacinių architektūrų tyrimo kontekste.

Literatūra ir šaltiniai

- [AA25] M. Q. Ansari, M. Q. Ansari. „Accelerating Matrix Multiplication: A Performance Comparison Between Multi-Core CPU and GPU“. Iš: *arXiv preprint arXiv:2507.19723* (2025).
- [AI24] M. AI. *Llama 3.1 8B*. 2024. URL: <https://ai.meta.com/blog/meta-llama-3-1/> (žiūrėta 2025-11-15).
- [AI25a] G. AI. *Gemma 3 12B*. 2025. URL: <https://deepmind.google/models/gemma/gemma-3/> (žiūrėta 2025-12-20).
- [AI25b] G. AI. *Gemma 3 4B*. 2025. URL: <https://deepmind.google/models/gemma/gemma-3/> (žiūrėta 2025-11-15).
- [Ama24] X. Amatriain. „Prompt design and engineering: Introduction and advanced methods“. Iš: *arXiv preprint arXiv:2401.14423* (2024).
- [Yoa] N. S. Yoav Katz. *Project Debater Datasets*. URL: https://research.ibm.com/haifa/dept/vst/debating_data.shtml (žiūrėta 2025-12-20).
- [KJA⁺24] D. Kumar, U. Jain, S. Agarwal, P. Harshangi. „Investigating Implicit Bias in Large Language Models: A Large-Scale Study of Over 50 LLMs“. Iš: *arXiv preprint arXiv:2410.12864* (2024).
- [LDC⁺24] H. Li, Q. Dong, J. Chen, H. Su, Y. Zhou, Q. Ai, Z. Ye, Y. Liu. „Llms-as-judges: a comprehensive survey on llm-based evaluation methods“. Iš: *arXiv preprint arXiv:2412.05579* (2024).
- [MDH⁺24] X. Mou, X. Ding, Q. He, L. Wang ir kiti. „From Individual to Society: A Survey on Social Simulation Driven by Large Language Model-based Agents“. Iš: *arXiv preprint arXiv:2412.03563* (2024).
- [Mis23] MistralAI. *Mistral 7B*. 2023. URL: <https://mistral.ai/news/announcing-mistral-7b> (žiūrėta 2025-11-15).
- [Ope25a] OpenAI. *gpt-oss-120b*. 2025. URL: <https://openai.com/index/introducing-gpt-oss/> (žiūrėta 2025-12-20).
- [Ope25b] OpenAI. *gpt-oss-20b*. 2025. URL: <https://openai.com/index/introducing-gpt-oss/> (žiūrėta 2025-12-20).
- [PJL⁺25] S. Park, S. Jeon, C. Lee, S. Jeon, B.-S. Kim, J. Lee. „A Survey on Inference Engines for Large Language Models: Perspectives on Optimization and Efficiency“. Iš: *arXiv preprint arXiv:2505.01658* (2025).
- [POC⁺23] J. S. Park, J. O'Brien, C. J. Cai, M. R. Morris, P. Liang, M. S. Bernstein. „Generative agents: Interactive simulacra of human behavior“. Iš: *Proceedings of the 36th annual acm symposium on user interface software and technology*. 2023, puslapiai 1–22.
- [Pra] G. Prasad. *Comparing AI agent frameworks: CrewAI, LangGraph, and BeeAI*. URL: <https://developer.ibm.com/articles/awb-comparing-ai-agent-frameworks-crewai-langgraph-and-beeai/> (žiūrėta 2025-10-20).

- [SIB⁺24] S. Schulhoff, M. Ilie, N. Balepur, K. Kahadze ir kiti. „The prompt report: A systematic survey of prompting techniques“. Iš: *arXiv preprint arXiv:2406.06608* 5 (2024).
- [SJE14] F. Squazzoni, W. Jager, B. Edmonds. „Social simulation in the social sciences: A brief overview“. Iš: *Social Science Computer Review* 32.3 (2014), puslapiai 279–294.
- [SSF⁺23] N. Scherrer, C. Shi, A. Feder, D. Blei. „Evaluating the moral beliefs encoded in llms“. Iš: *Advances in Neural Information Processing Systems* 36 (2023), puslapiai 51778–51809.
- [WWT⁺25] Q. Wang, J. Wu, Z. Tang, B. Luo, N. Chen, W. Chen, B. He. „What Limits LLM-based Human Simulation: LLMs or Our Design?“ Iš: *arXiv preprint arXiv:2501.08579* (2025).